

Universidade Federal de Minas Gerais
Curso de Engenharia de Sistemas
Trabalho de Conclusão de Curso II

Visão Geral do Projeto
INCENTIVO AO ECODRIVING VIA ANÁLISE
DE DADOS VEICULARES E APRENDIZADO
FEDERADO

Versão:02.00

Data:29/03/2026

Aluno: Lorenzo Bicalho dos Santos Lopes

Histórico de revisões

Versão (XX.YY)	Data (DD/MMM/YYYY)	Autor	Descrição
01.00	19/05/2025	Lorenzo Bicalho dos Santos Lopes	Entrega da Visão Geral para o TCC I
02.00	29/03/2026	Lorenzo Bicalho dos Santos Lopes	Entrega da Visão Geral para o TCC II

Sumário

1. INTRODUÇÃO.....	5
1.1. PROPÓSITO.....	5
1.2. PÚBLICO ALVO.....	5
1.3. MOTIVAÇÃO E JUSTIFICATIVA.....	5
1.4. OBJETIVOS.....	6
1.5. LOCAL DE REALIZAÇÃO.....	6
1.6. VISÃO GERAL DO DOCUMENTO.....	7
2. VISÃO GERAL DO TRABALHO.....	8
2.1. ESCOPO DO TRABALHO.....	8
2.2. REVISÃO BIBLIOGRÁFICA.....	9
3. METODOLOGIA E CRONOGRAMA.....	11
4. REFERÊNCIAS BIBLIOGRÁFICAS.....	13

1. Introdução

1.1. Propósito

Este documento especifica o trabalho a ser desenvolvido pelo aluno de Engenharia de Sistemas Lorenzo Bicalho dos Santos Lopes, fornecendo ao professor orientador e ao professor da disciplina as informações necessárias para sua avaliação e aprovação. Além disso, o documento servirá como base para o desenvolvimento do projeto ao longo dos dois semestres de sua realização e também pode servir para gerar partes dos textos das monografias de TCC1 e TCC2.

1.2. Público Alvo

Este documento se destina ao aluno e aos profissionais envolvidos na orientação de seu trabalho de conclusão de curso.

1.3. Motivação e justificativa

Os comportamentos de condução de motoristas são relevantes devido aos impactos diretos na segurança viária, no consumo de combustível, na emissão de poluentes e nos custos operacionais de veículos e frotas. Este trabalho é direcionado principalmente para o contexto ambiental, ao abordar o conceito de *ecodriving*, buscando promover práticas de condução mais eficientes e sustentáveis. Consequentemente, a adoção dessas práticas também pode gerar impactos indiretos em outras frentes, como a melhoria da segurança viária e a redução do desgaste de componentes mecânicos. Nesse contexto, este trabalho busca contribuir para a otimização das emissões de poluentes associadas ao estilo de direção de um motorista, ao mesmo tempo em que mantém princípios de privacidade em relação aos seus dados, por meio do processamento local das informações e do uso de técnicas de aprendizado distribuído.

Questões relacionadas à energia e às mudanças climáticas têm ganhado destaque global nas últimas décadas, especialmente após a definição, em setembro de 2015, dos 17 Objetivos de Desenvolvimento Sustentável (ODS) pela Organização das Nações Unidas. Ainda em 2015, a adoção do Acordo de Paris durante a Conferência das Nações Unidas sobre Mudanças Climáticas reafirmou a urgência de ações globais coordenadas no enfrentamento do aquecimento global. Dentre os setores de maior impacto ambiental, destaca-se o setor de transportes, especialmente nas áreas urbanas, como um dos maiores consumidores de energia e principais emissores de gases de efeito estufa. Esse cenário torna o setor de transportes uma peça-chave tanto na origem dos problemas ambientais quanto no desenvolvimento de soluções sustentáveis. Considerando a influência direta das práticas de condução sobre o consumo energético e as emissões veiculares, torna-se essencial o desenvolvimento de métodos eficazes para a classificação e análise de estilos de direção, bem como para o fornecimento de *feedback* ao motorista, de modo a incentivar comportamentos mais eficientes e ambientalmente responsáveis.

A realização deste trabalho pode proporcionar benefícios relevantes tanto do ponto de vista ambiental quanto operacional e social. Espera-se que a solução proposta contribua para a promoção de práticas de condução mais sustentáveis, possibilitando a redução do consumo de combustível e das emissões de poluentes, o que favorece diretamente a

sustentabilidade ambiental e a mitigação dos impactos associados ao setor de transportes. Além disso, o sistema proposto pode contribuir para a preservação da privacidade dos usuários, por meio do uso de técnicas como aprendizado federado e processamento local dos dados, reduzindo a necessidade de compartilhamento de informações sensíveis.

De forma complementar, a adoção de práticas de condução mais eficientes tende a gerar benefícios indiretos, como a promoção de comportamentos de direção mais seguros, a diminuição de custos operacionais relacionados à manutenção veicular e ao desgaste de componentes mecânicos, bem como a redução da probabilidade de acidentes. Dessa forma, o trabalho não apenas atende a demandas ambientais contemporâneas, mas também apresenta potencial para gerar ganhos econômicos e operacionais em contextos individuais e organizacionais.

1.4. Objetivos

Este trabalho tem como objetivo geral desenvolver uma solução tecnológica voltada à promoção de práticas de condução mais sustentáveis, contribuindo para a mitigação dos impactos ambientais associados ao setor de transportes, ao mesmo tempo em que assegura a privacidade dos dados dos motoristas por meio de técnicas de processamento local e aprendizado distribuído.

Os objetivos específicos deste trabalho consistem em projetar e implementar o hardware embarcado responsável pela aquisição de dados veiculares em tempo real; desenvolver um algoritmo de classificação capaz de identificar estilos de condução com base em parâmetros do carro; implementar mecanismos de aprendizado federado para permitir a atualização contínua do modelo de forma distribuída e preservando a privacidade dos dados; desenvolver um servidor central responsável pelo gerenciamento dos modelos, armazenamento de parâmetros e comunicação com os dispositivos embarcados; implementar um sistema de *feedback* ao motorista, com o objetivo de incentivar práticas de condução mais eficientes e sustentáveis; e realizar testes e análises experimentais para avaliar o desempenho do sistema proposto em termos de classificação de estilos de condução e impacto potencial sobre indicadores de eficiência energética e sustentabilidade ambiental.

1.5. Local de realização

O projeto é realizado no laboratório FutureLab da UFMG. O laboratório de pesquisa multidisciplinar FutureLab é um centro de excelência dedicado à pesquisa e inovação em inteligência artificial, ciência de dados, sistemas complexos e transformação digital. Localizado em Belo Horizonte, o laboratório reúne pesquisadores de ponta, promovendo a integração entre academia, mercado e sociedade para o desenvolvimento de soluções tecnológicas avançadas. Com uma infraestrutura moderna e foco na colaboração interdisciplinar, atua como referência em projetos de pesquisa aplicada, transferência de conhecimento e desenvolvimento tecnológico, abrangendo áreas como modelagem de sistemas complexos, análise de grandes volumes de dados e implementação de tecnologias que promovem eficiência e inovação.

1.6. Visão geral do documento

- **A seção 2** apresenta uma visão geral do trabalho, caracterizando o seu escopo e efetuando uma breve revisão bibliográfica sobre o assunto, permitindo situar claramente o trabalho proposto em relação a outros apresentados na literatura;
- **Na seção 3** é descrita a metodologia a ser empregada no trabalho a ser desenvolvido;
- **A seção 4** apresenta as referências bibliográficas utilizadas.

2. Visão Geral do Trabalho

Este trabalho propõe o desenvolvimento de uma solução voltada à promoção de práticas de condução mais seguras e sustentáveis, por meio da coleta, análise e processamento inteligente de dados comportamentais de motoristas. O foco da pesquisa está na criação de um hardware embarcado para coleta de dados em tempo real, no desenvolvimento de algoritmos de classificação capazes de identificar padrões de comportamento ao volante e na aplicação de técnicas de aprendizado federado, garantindo a segurança e a privacidade dos dados dos usuários. Também será implementado um sistema de *feedback* local, com o objetivo de incentivar a mudança de comportamento dos motoristas por meio de intervenções diretas. Para avaliação da efetividade da solução, serão realizadas comparações entre os dados obtidos antes e depois da aplicação do sistema proposto.

2.1. Escopo do trabalho

No contexto do hardware embarcado, o projeto contempla o desenvolvimento e integração de um sistema composto por uma plataforma baseada em FPGA DE10, responsável pela execução local de inferência e treinamento do modelo de classificação, e um dispositivo Raspberry Pi, encarregado da aquisição de dados provenientes da rede CAN do veículo por meio da porta OBD2, além da comunicação com o servidor central. O escopo inclui a implementação dos mecanismos de leitura, armazenamento temporário e transmissão dos dados coletados.

No âmbito dos algoritmos de inteligência artificial, o projeto abrange a implementação de um modelo de classificação baseado em um sistema neuro-fuzzy, utilizando a estrutura de inferência de Sugeno e treinamento por meio do método do gradiente descendente. A implementação será realizada de forma analítica, sem a utilização de bibliotecas de alto nível consideradas "caixa-preta", de modo a possibilitar futura implementação em hardware embarcado com restrições computacionais e de memória. Também fazem parte do escopo as adaptações necessárias para utilização de funções de pertinência do tipo gaussiana.

No que se refere à infraestrutura computacional, o projeto inclui o desenvolvimento de um servidor responsável pela coordenação do processo de aprendizado federado, permitindo a evolução contínua do modelo global a partir dos modelos treinados localmente nos dispositivos embarcados, preservando a privacidade dos dados dos usuários. O escopo contempla a implementação de um banco de dados destinado ao armazenamento dos pesos globais do modelo, dos pesos recebidos dos clientes locais e de informações associadas ao versionamento e gerenciamento do modelo.

Adicionalmente, o projeto prevê a implementação de um sistema local de *feedback* sonoro ao motorista, com o objetivo de incentivar a adoção de comportamentos de condução mais seguros e eficientes, por meio da apresentação de informações e recomendações baseadas no estilo de direção identificado.

Por fim, o escopo inclui a avaliação da efetividade da solução proposta por meio da comparação entre dados coletados antes e após a utilização do sistema, permitindo analisar o impacto da ferramenta no comportamento dos motoristas.

Não fazem parte do escopo deste trabalho o desenvolvimento de interfaces web, aplicativos móveis ou plataformas de visualização em nuvem. Tais elementos, embora relevantes para a ampliação e escalabilidade da solução, estão fora do objetivo central da presente pesquisa, que se concentra na prova de conceito da coleta e processamento embarcado.

O projeto está inserido no escopo mais amplo do Programa de Mobilidade Verde e Inovação (Mover), iniciativa do Governo Federal sancionada em junho de 2024 como substituta do Rota 2030. O Mover visa modernizar a indústria automotiva brasileira por meio do estímulo à inovação tecnológica e da adoção de metas ambientais rigorosas, como a redução de emissões e o aumento da eficiência energética dos veículos. Alinhado a essas diretrizes, este trabalho contribui ao propor uma tecnologia acessível, eficiente e segura para monitoramento de condutores, promovendo não apenas melhorias no desempenho ambiental dos veículos, mas também avanços em segurança viária.

A situação atual, marcada pela escassez de soluções embarcadas de baixo custo capazes de realizar esse tipo de análise em tempo real com respeito à privacidade, será contrastada com o cenário pós-desenvolvimento do protótipo, no qual se espera alcançar um sistema funcional capaz de gerar impactos positivos no comportamento de condução e, consequentemente, na sustentabilidade e segurança do trânsito urbano.

2.2. Revisão bibliográfica

Diante das limitações das tecnologias tradicionais de economia de combustível, dos desafios para mitigar congestionamentos urbanos e da ainda baixa adesão de veículos movidos a energias alternativas, o *eco-driving* surge como uma alternativa viável e de rápida implementação para promover a eficiência energética e a redução de emissões no setor de transportes no curto prazo (Xu et al, 2021).

Além dos sensores, diversos métodos de coleta e avaliação de comportamento de condutores foram discutidos por Ghatee e Ef tekhari (2018), incluindo questionários autodeclarados, simuladores de direção, avaliação por especialistas, registradores embarcados e sensores de smartphones. Cada um desses métodos possui vantagens e desvantagens específicas. Por exemplo, questionários são de baixo custo, mas altamente sujeitos à memória e percepção do motorista; simuladores permitem a simulação de cenários críticos, mas não garantem realismo; enquanto sensores embarcados fornecem dados em tempo real, porém com custo elevado e possibilidade de manipulação.

De forma geral, a maioria dos estudos adota uma classificação em três grupos principais: agressivo, normal e cauteloso (DORR; GRABENGIESSER; GAUTERIN, 2014; HIGGS; ABBAS, 2013; XU et al., 2015). Essa abordagem busca representar um espectro de comportamentos que varia desde manobras arriscadas e impulsivas até condução defensiva e previsível.

A identificação de eventos de direção agressiva é fundamental para avaliar o comportamento do condutor e seu impacto tanto na segurança quanto na eficiência energética. Estudos indicam que variáveis como velocidade, aceleração, frenagem, localização, quilometragem e variações temporais estão entre os principais parâmetros para avaliação de risco de acidentes (SINGH; KATHURIA, 2021).

O Aprendizado Federado (Federated Learning – FL) tem se consolidado como uma solução eficaz para o desenvolvimento de modelos de aprendizado de máquina em cenários com alta fragmentação de dados, especialmente em contextos regulatórios que

priorizam a privacidade dos indivíduos. Nessa abordagem distribuída, os dados permanecem nos dispositivos locais e apenas os parâmetros dos modelos são compartilhados entre as entidades participantes, garantindo que a privacidade seja preservada ao longo de todo o processo (Ramos et al, 2021).

Soluções baseadas em gamificação têm ganhado destaque. Uma revisão sistemática analisou 39 estudos que exploraram o uso de elementos lúdicos, como pontuações, recompensas, rankings e visualizações criativas como *emojis* ou árvores que crescem conforme a performance melhora. Esses sistemas, muitas vezes implementados em aplicativos móveis, mostraram resultados promissores, como a redução de velocidade e o aumento da eficiência no consumo de combustível (STEPHENS, 2022).

3. Metodologia e Cronograma

A realização deste trabalho foi dividida em etapas sucessivas, contemplando desde a pesquisa exploratória até a validação final do sistema desenvolvido. A abordagem adotada possui caráter experimental e aplicado, com foco na integração entre hardware e software embarcado, aprendizado de máquina e técnicas de aprendizado federado. A seguir, detalham-se as principais atividades, os métodos e as ferramentas utilizadas em cada fase do projeto.

Inicialmente, durante os meses de março e abril de 2025, foi conduzida uma etapa de pesquisa e levantamento bibliográfico. Esse esforço contemplou o estudo aprofundado sobre a rede CAN (*Controller Area Network*), amplamente empregada em veículos modernos para comunicação entre módulos eletrônicos, além da identificação dos sensores e componentes necessários para a coleta de dados veiculares. Simultaneamente, foi realizada uma revisão da literatura sobre classificação de estilos de direção e sistemas embarcados de monitoramento comportamental, a fim de embasar as decisões técnicas das etapas posteriores.

Em maio de 2025, foi desenvolvido o algoritmo de classificação ANFIS (*Adaptive Neuro-Fuzzy Inference System*) para identificação de estilos de condução, utilizando o ambiente MATLAB. Essa fase incluiu a utilização de bases de dados públicas previamente coletadas e disponibilizadas online. Como tais bases não apresentam rotulagem explícita dos estilos de condução, foi desenvolvida uma metodologia de rotulagem semi-supervisionada com apoio do ambiente MATLAB, baseada em critérios como aceleração, frenagem e variação lateral do veículo.

No mês de junho de 2025, foi iniciado o desenvolvimento do hardware de coleta de dados. Nessa etapa, foram adquiridos produtos comerciais disponíveis no mercado para referência e validação de componentes. Inicialmente, foram realizados testes utilizando microcontroladores da família ESP32 ou similares, programados em linguagem C/C++ nas plataformas *PlatformIO* ou *Arduino IDE*. Entretanto, os resultados obtidos não atenderam aos requisitos de desempenho e estabilidade do sistema, o que levou à substituição da plataforma por um computador embarcado *Raspberry Pi*. O foco dessa etapa foi garantir a captação eficiente dos dados da rede CAN, bem como a integração com sensores adicionais, como giroscópio. Foram realizados testes de bancada e testes iniciais em veículos reais para assegurar a funcionalidade da comunicação com os sistemas embarcados automotivos.

No segundo semestre de 2025, o desenvolvimento do projeto foi temporariamente interrompido em função da realização de um intercâmbio acadêmico.

Em março de 2026, foi desenvolvido e incorporado ao sistema o módulo de aprendizado federado. Essa abordagem permite o treinamento contínuo dos modelos de forma distribuída, sem que os dados brutos sejam compartilhados entre dispositivos, garantindo, assim, a privacidade dos usuários. Nessa etapa, foi implementado um servidor em linguagem *Python*, utilizando comunicação via *sockets* e um banco de dados PostgreSQL para armazenamento dos pesos do modelo e das informações associadas ao seu gerenciamento.

A partir de abril de 2026, será realizada a coleta de dados em campo com motoristas voluntários. Essa coleta será conduzida inicialmente sem a presença de *feedback* em tempo real, permitindo uma análise imparcial dos estilos de condução. Os dados

obtidos alimentarão o modelo de classificação, que será continuamente ajustado com o objetivo de aumentar sua robustez e confiabilidade. As análises preliminares buscarão verificar a coerência entre os padrões detectados e os perfis de condução esperados.

Em maio de 2026, será implementado o sistema de *feedback* embarcado. Por meio de notificações sonoras, o sistema fornecerá retorno imediato ao condutor sobre seu comportamento ao volante. O objetivo dessa etapa é incentivar mudanças positivas na condução e reduzir a ocorrência de eventos de risco.

Por fim, em junho de 2026, será realizada uma análise abrangente dos dados obtidos ao longo de todo o projeto. A comparação entre os dados coletados antes e após a introdução do sistema de *feedback* permitirá avaliar sua efetividade na modificação do comportamento de condução. Além disso, será conduzida uma análise da viabilidade técnica e dos benefícios decorrentes da aplicação do aprendizado federado, incluindo métricas de desempenho do modelo, utilização de recursos computacionais e nível de privacidade alcançado.

Cronograma do Projeto:

Março – Abril/2025: Pesquisa teórica, estudo da rede CAN, definição de sensores e revisão bibliográfica.

Maio/2025: Desenvolvimento do algoritmo de classificação ANFIS; rotulagem semi-supervisionada de dados e testes iniciais de modelos de aprendizado de máquina.

Junho/2025: Projeto, aquisição e montagem inicial do hardware de coleta; testes de comunicação com a rede CAN e avaliação de plataformas embarcadas.

Julho – Dezembro/2025: Interrupção temporária do projeto devido à realização de intercâmbio acadêmico.

Janeiro – Fevereiro/2026: Retomada das atividades do projeto, ajustes no sistema embarcado e preparação da infraestrutura computacional.

Março/2026: Implementação e integração do módulo de aprendizado federado; desenvolvimento do servidor, comunicação via *sockets* e configuração do banco de dados.

Abril/2026: Início da coleta de dados em campo com motoristas voluntários, sem utilização de *feedback* em tempo real.

Maio/2026: Implementação do sistema de *feedback* embarcado e início da coleta de dados com intervenção comportamental.

Junho/2026: Análise final dos dados coletados, comparação de desempenho antes e depois do sistema de *feedback* e avaliação do funcionamento completo da solução.

4. Referências bibliográficas

XU, Nan; LI, Xiaohan; LIU, Qiao; ZHAO, Di. An Overview of Eco-Driving Theory, Capability Evaluation, and Training Applications. *Sensors*, v. 21, n. 19, art. 6547, 2021. DOI: 10.3390/s21196547. Disponível em: <https://www.mdpi.com/1424-8220/21/19/6547>. Acesso em: 19 maio 2025.

GHATEE, Mehdi; EFTEKHARI, Hamid. Hybrid of discrete wavelet transform and adaptive neuro fuzzy inference system for overall driving behavior recognition. *Transportation Research Part F: Traffic Psychology and Behaviour*, v. 58, p. 782–796, jul. 2018. DOI: 10.1016/j.trf.2018.06.044.

DÖRR, Dominik; GRABENGISSER, David; GAUTERIN, Frank. Online driving style recognition using fuzzy logic. In: 17th International IEEE Conference on Intelligent Transportation Systems (ITSC), 2014. Anais... IEEE, 2014. p. 1021–1026.

HIGGS, Bryan; ABBAS, Montasir. A two-step segmentation algorithm for behavioral clustering of naturalistic driving styles. In: 16th International IEEE Conference on Intelligent Transportation Systems (ITSC 2013). Anais... IEEE, 2013. p. 857–862.

SINGH, Harpreet; KATHURIA, Ankit. Profiling drivers to assess safe and eco-driving behavior – A systematic review of naturalistic driving studies. *Accident Analysis & Prevention*, v. 161, p. 106349, 2021. DOI: 10.1016/j.aap.2021.106349. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0001457521003808>. Acesso em: 19 maio 2025.

RAMOS, Heitor S. et al. Aprendizado Federado aplicado à Internet das Coisas. In: XXXIX Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2021). Brasil: SBC, 2021. cap. 5.

STEPHENS, Richard. A review of gamified approaches to encouraging eco-driving. *Frontiers in Psychology*, v. 13, art. 970851, set. 2022. DOI: 10.3389/fpsyg.2022.970851.