

UNIVERSIDADE FEDERAL DE MINAS GERAIS  
DEE - DEPARTAMENTO DE ENGENHARIA ELÉTRICA  
CURSO DE ENGENHARIA DE SISTEMAS

LORENZO BICALHO DOS SANTOS LOPES

**SISTEMA INTELIGENTE PARA INCENTIVO AO ECODRIVING VIA  
ANÁLISE DE DADOS VEICULARES E APRENDIZADO FEDERADO**

TRABALHO DE CONCLUSÃO DE CURSO

BELO HORIZONTE  
2025

LORENZO BICALHO DOS SANTOS LOPES

**SISTEMA INTELIGENTE PARA INCENTIVO AO ECODRIVING VIA  
ANÁLISE DE DADOS VEICULARES E APRENDIZADO FEDERADO**

Trabalho de Conclusão de Curso apresentado ao Curso de Engenharia de Sistemas da Universidade Federal de Minas Gerais, como requisito parcial para a obtenção do título de Bacharel em Engenharia de Sistemas.

Orientadora: Gabriela N. Lopes  
Universidade Federal de Minas Gerais  
(UFMG), Belo Horizonte, MG, Brasil

Coorientador: Roberto G. Ribeiro  
Universidade Federal de Ouro Preto (UFOP),  
João Monlevade, MG, Brasil

BELO HORIZONTE  
2025

Altere este texto inserindo a dedicatória do seu trabalho.

## **AGRADECIMENTOS**

Edite e coloque aqui os agradecimentos às pessoas e/ou instituições que contribuíram para a realização do trabalho.

É obrigatório o agradecimento às instituições de fomento à pesquisa que financiaram total ou parcialmente o trabalho, inclusive no que diz respeito à concessão de bolsas.

*Eu denomino meu campo de Gestão do Conhecimento, mas você não pode gerenciar conhecimento. Ninguém pode. O que pode fazer - o que a empresa pode fazer - é gerenciar o ambiente que otimize o conhecimento. (PRUSAK, Laurence, 1997).*

## RESUMO

BICALHO, Lorenzo. Sistema Inteligente para Incentivo ao Ecodriving via Análise de Dados Veiculares e Aprendizado Federado . 2025. 49 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Sistemas, Universidade Federal de Minas Gerais. Belo Horizonte, 2025.

O Resumo é um elemento obrigatório em tese, dissertação, monografia e TCC, constituído de uma sequência de frases concisas e objetivas, fornecendo uma visão rápida e clara do conteúdo do estudo. O texto deverá conter no máximo 500 palavras e ser antecedido pela referência do estudo. Também, não deve conter citações. O resumo deve ser redigido em parágrafo único, espaçamento simples e seguido das palavras representativas do conteúdo do estudo, isto é, palavras-chave, em número de três a cinco, separadas entre si por ponto e finalizadas também por ponto. Usar o verbo na terceira pessoa do singular, com linguagem impessoal, bem como fazer uso, preferencialmente, da voz ativa. Texto contendo um único parágrafo.

**Palavras-chave:** Palavra. Segunda Palavra. Outra palavra.

## ABSTRACT

BICALHO, Lorenzo. Title in English. 2025. 49 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Sistemas, Universidade Federal de Minas Gerais. Belo Horizonte, 2025.

Elemento obrigatório em tese, dissertação, monografia e TCC. É a versão do resumo em português para o idioma de divulgação internacional. Deve ser antecedido pela referência do estudo. Deve aparecer em folha distinta do resumo em língua portuguesa e seguido das palavras representativas do conteúdo do estudo, isto é, das palavras-chave. Sugere-se a elaboração do resumo (Abstract) e das palavras-chave (Keywords) em inglês; para resumos em outras línguas, que não o inglês, consultar o departamento / curso de origem.

**Keywords:** Word. Second Word. Another word.

## LISTA DE FIGURAS

Figura 1 – Série temporal da velocidade e aceleração normalizadas para uma viagem do motorista A. . . . .	17
Figura 2 – Relação entre velocidade, aceleração e grau de pertinência fuzzy, onde azul escuro indica condução calma e vermelho escuro, condução agressiva. . . .	18
Figura 3 – Relação entre RPM, pedal do acelerador, deflexão do volante e aceleração no cálculo do score de agressividade do classificador determinístico. . . . .	19
Figura 4 – Série temporal da velocidade e da classificação do estilo de condução utilizando o método baseado em jerk, com janelas de aproximadamente 10 segundos, ao longo de 200 segundos de uma viagem. . . . .	20
Figura 5 – Exemplo de Figura . . . . .	28



## LISTA DE QUADROS

Quadro 1 – Exemplo de Quadro. . . . .	29
---------------------------------------	----

## LISTA DE TABELAS

Tabela 1 – Resumo estatístico por grupo com médias das variáveis selecionadas . . . .	21
Tabela 2 – Coincidência entre classificadores . . . . .	21
Tabela 3 – Distribuição de Grupos por Cluster (Análise Cruzada) . . . . .	22
Tabela 4 – Médias das Variáveis por Cluster . . . . .	22
Tabela 5 – Resultado dos testes . . . . .	29

## **LISTA DE ABREVIATURAS E SIGLAS**

ABNT	Associação Brasileira de Normas Técnicas
DECOM	Departamento de Computação

## LISTA DE SÍMBOLOS

$\Gamma$	Letra grega Gama
$\lambda$	Comprimento de onda
$\in$	Pertence

## LISTA DE ALGORITMOS

Algoritmo 1 – Exemplo de Algoritmo . . . . .	31
--	----

## SUMÁRIO

<b>1 – INTRODUÇÃO</b>	<b>1</b>
<b>2 – Revisão de Literatura</b>	<b>4</b>
2.1 Eco-driving	4
2.2 Coleta de Dados Veiculares	5
2.3 Dados da Rede CAN	6
2.4 Classificação de Estilos de Direção	7
2.5 Eventos Indicadores de Comportamento Agressivo	7
2.6 Algoritmos de Classificação	8
2.7 Aprendizado Federado	9
2.8 Sistemas de Feedback	10
<b>3 – METODOLOGIA</b>	<b>12</b>
3.1 Rotulagem dos Dados (Data Labeling)	13
3.1.1 Coleta de Dados	13
3.1.2 Extração de características (Features)	14
3.1.2.1 Aceleração normalizada (acc_norm)	14
3.1.2.2 Deflexão do volante	15
3.1.2.3 Jerk	15
3.1.3 K-means	16
3.1.4 Análise Cruzada com Classificações Independentes	16
3.1.4.1 Classificação Fuzzy	16
3.1.4.2 Classificação Determinística	17
3.1.4.3 Classificação por Jerk	19
3.1.4.4 Agrupamento por Concordância de Classificações	19
3.1.5 Resultados da Rotulagem	20
3.1.6 Interpretação dos Dados	23
3.1.7 Considerações Parciais	24
3.2 Desenvolvimento do Algoritmo Neuro-Fuzzy	25
3.3 Desenvolvimento do Hardware para Coleta de Dados	25
3.4 Desenvolvimento do Algoritmo de Aprendizado Federado	25
3.5 Desenvolvimento de Sistema de Feedback	25
<b>4 – ANÁLISE E DISCUSSÃO DOS RESULTADOS</b>	<b>26</b>
<b>5 – SOBRE AS ILUSTRAÇÕES</b>	<b>27</b>

<b>6 – FIGURAS</b>	<b>28</b>
<b>7 – QUADROS E TABELAS</b>	<b>29</b>
<b>8 – EQUAÇÕES</b>	<b>30</b>
<b>9 – ALGORITMOS</b>	<b>31</b>
<b>10 – SOBRE AS LISTAS</b>	<b>32</b>
<b>11 – SOBRE AS CITAÇÕES E CHAMADAS DE REFERÊNCIAS</b>	<b>33</b>
<b>12 – CITAÇÕES INDIRETAS</b>	<b>34</b>
<b>13 – CITAÇÕES DIRETAS</b>	<b>35</b>
<b>14 – DETALHES SOBRE AS CHAMADAS DE REFERÊNCIAS</b>	<b>36</b>
<b>15 – SOBRE AS REFERÊNCIAS BIBLIOGRÁFICAS</b>	<b>37</b>
<b>16 – NOTAS DE RODAPÉ</b>	<b>38</b>
<b>17 – CONCLUSÃO</b>	<b>39</b>
17.1 TRABALHOS FUTUROS	39
17.2 CONSIDERAÇÕES FINAIS	39
<b>Referências</b>	<b>40</b>
 <b>Apêndices</b>	 <b>44</b>
<b>APÊNDICE A – Nome do apêndice</b>	<b>45</b>
<b>APÊNDICE B – Nome do outro apêndice</b>	<b>46</b>
 <b>Anexos</b>	 <b>47</b>
<b>ANEXO A – Nome do anexo</b>	<b>48</b>
<b>ANEXO B – Nome do outro anexo</b>	<b>49</b>

## 1 INTRODUÇÃO

Questões relacionadas à energia e às mudanças climáticas têm ganhado destaque global, especialmente após a definição, em setembro de 2015, dos 17 Objetivos de Desenvolvimento Sustentável (ODS) pela Organização das Nações Unidas (ONU). Para atingir tais metas, é necessário o comprometimento de diferentes setores, com destaque para o setor energético, uma vez que a energia é elemento fundamental para todas as atividades de desenvolvimento (SIMSEK et al., 2020). Ainda em 2015, a adoção do Acordo de Paris durante a Conferência das Nações Unidas sobre Mudanças Climáticas reafirmou a urgência de ações globais coordenadas no enfrentamento do aquecimento global (PAN et al., 2020).

Nesse contexto, o Grand Challenges Scholars Program (GCSP) e sua rede internacional de instituições de ensino em engenharia foram criados com o objetivo de formar profissionais preparados para enfrentar os grandes desafios contemporâneos da humanidade. Proposto pela National Academy of Engineering (NAE) em 2008, o programa delineou 14 Grandes Desafios da Engenharia, agrupados em quatro grandes eixos: Sustentabilidade, Saúde, Segurança e Alegria de Viver. Mesmo diante da constante transformação dos problemas sociais e ambientais, a missão do GCSP permanece atual: capacitar engenheiros multidisciplinares que, munidos de conhecimento técnico e sensibilidade social, consigam atuar em contextos diversos para converter fenômenos complexos em soluções úteis para a sociedade (USC Viterbi School of Engineering, 2025).

Entre os desafios propostos, destacam-se alguns com forte relação com o presente trabalho, como “Tornar a energia solar economicamente viável” e “Desenvolver métodos de sequestro de carbono”, ambos no eixo da Sustentabilidade. Esses desafios envolvem a busca por tecnologias e políticas que possibilitem uma transição energética justa e eficiente, contribuindo diretamente para a mitigação das mudanças climáticas. No eixo da Segurança, o desafio “Restaurar e melhorar a infraestrutura urbana” também se mostra pertinente, especialmente diante da crescente complexidade dos sistemas de mobilidade urbana e da necessidade de soluções inteligentes, sustentáveis e inclusivas para o transporte nas cidades.

Dentre os setores de maior impacto ambiental, destaca-se o setor de transportes, especialmente nas áreas urbanas, como um dos maiores consumidores de energia e principais emissores de gases de efeito estufa. Isso torna esse setor peça-chave tanto nos problemas ambientais quanto nas suas potenciais soluções (VUJIĆ; ŠEMANJSKI; VIDAN, 2015).

No contexto nacional, o Brasil tem buscado alinhar sua indústria automotiva às metas globais de sustentabilidade por meio do Programa de Mobilidade Verde e Inovação (Mover), sancionado em junho de 2024 como substituto do Rota 2030. A iniciativa amplia as exigências ambientais para o setor automotivo, promovendo a adoção de tecnologias mais limpas e eficientes (FUNDEP/UFMG, 2025).

Com foco em inovação e descarbonização, o programa estabelece diretrizes obrigatórias



para novos veículos produzidos ou importados no país, incluindo metas de eficiência energética, aumento do uso de materiais recicláveis e incorporação de tecnologias avançadas de segurança veicular. Uma das novidades é a criação do chamado “IPI Verde”, sistema tributário progressivo que beneficia fabricantes com menor impacto ambiental ([CNN Brasil, 2024](#)).

O Mover também prevê metas ambiciosas de redução de emissões: uma queda média de 12% no consumo energético até 2031 no ciclo “tanque à roda”, em comparação aos modelos de 2022, e uma redução de 50% nas emissões de carbono no ciclo “poço à roda” até 2030, tomando como base os níveis de 2011 ([CNN Brasil, 2024](#)). A regulamentação inclui ainda a exigência de rotulagem ambiental, o que incentiva a transparência e estimula o consumidor a optar por veículos mais sustentáveis.

Desde sua criação, o programa já impulsionou a promessa de mais de R\$130 bilhões em investimentos no setor, envolvendo a ampliação de fábricas e o desenvolvimento de novas tecnologias automotivas ([FUNDEP/UFGM, 2025](#)).

Nesse cenário, o estudo e a aplicação de perfis de condução vêm ganhando relevância por sua ampla aplicabilidade em sistemas inteligentes de transporte. As informações sobre o estilo de direção dos motoristas podem ser utilizadas em iniciativas como gestão de frotas, seguros personalizados, programas de eco-condução e intervenções para segurança viária. Além disso, essas aplicações favorecem mudanças comportamentais por meio de feedbacks, avaliações de infraestrutura viária, treinamentos corporativos e estratégias de decisão em diferentes níveis — do estratégico ao operacional ([SINGH; KATHURIA, 2021](#)).

A crescente conectividade de veículos e a digitalização dos sistemas automotivos têm impulsionado o desenvolvimento de soluções inteligentes para a mobilidade urbana. Dentre essas soluções, destaca-se o monitoramento e a classificação de estilos de condução, que desempenham papel central em aplicações como manutenção preditiva, seguros personalizados, segurança veicular e gestão de frotas. Modelos de aprendizado de máquina (ML) vêm sendo amplamente utilizados nesse contexto, permitindo extrair padrões de comportamento a partir de dados telemáticos, como aceleração, frenagem e curvas.

Entretanto, o uso desses dados sensíveis impõe desafios significativos em termos de privacidade, especialmente diante de regulamentações mais rigorosas sobre o uso de informações pessoais. Nesse cenário, o Aprendizado Federado (Federated Learning – FL) surge como uma alternativa promissora. Essa abordagem permite o treinamento colaborativo de modelos sem a necessidade de centralizar os dados, respeitando as diretrizes de privacidade e segurança ([RAMOS et al., 2021](#)). No contexto automotivo, o FL tem se mostrado eficaz ao permitir que veículos conectados e autônomos (CAVs) treinem modelos localmente, compartilhando apenas atualizações dos parâmetros por meio de canais seguros, sem exposição direta das informações dos usuários ([CHEN; TORSTENSSON; ENGLUND, 2020](#); [CHELLAPANDI et al., 2023](#)).

Considerando a relevância das práticas de condução para o consumo energético, emissões veiculares e segurança no trânsito, torna-se essencial desenvolver métodos eficazes para a classificação e análise de estilos de direção. Diante disso, este trabalho tem como objetivo

investigar abordagens para o perfilamento de motoristas com foco em aplicações urbanas, especialmente aquelas que visam promover a condução eficiente e segura. A proposta inclui a análise de métodos estatísticos e baseados em inteligência artificial, bem como a avaliação da aplicabilidade do Aprendizado Federado (FL) como alternativa para garantir a privacidade dos dados e viabilizar a colaboração entre diferentes agentes sem comprometer a segurança da informação. Além disso, será implementado um sistema de feedback para os motoristas, seguido de uma análise comparativa dos resultados antes e depois da introdução do feedback, com o intuito de avaliar seu impacto na adoção do ecodriving.

A partir disso, busca-se contribuir para o avanço de tecnologias sustentáveis e inteligentes no setor de mobilidade urbana. O Capítulo 2 apresenta a fundamentação teórica com a revisão da literatura; o Capítulo 3 descreve a metodologia adotada; o Capítulo 4 expõe e analisa os resultados obtidos; e, por fim, o Capítulo 17 apresenta as conclusões do trabalho.

## 2 Revisão de Literatura

Este capítulo tem como objetivo apresentar os principais conceitos, abordagens e trabalhos relacionados ao tema deste projeto. Serão discutidos o conceito de eco-driving, as formas de coleta de dados veiculares, a utilização de dados da rede CAN, as estratégias para identificação de comportamentos agressivos na direção, os algoritmos de classificação utilizados na literatura e, por fim, os sistemas de feedback voltados à mudança de comportamento dos motoristas.

### 2.1 Eco-driving

Diante das limitações das tecnologias tradicionais de economia de combustível, dos desafios para mitigar congestionamentos urbanos e da ainda baixa adesão de veículos movidos a energias alternativas, o eco-driving surge como uma alternativa viável e de rápida implementação para promover a eficiência energética e a redução de emissões no setor de transportes no curto prazo (XU et al., 2021).

O termo eco-driving refere-se a um conjunto de práticas que visam otimizar o consumo de energia durante a condução de veículos. Segundo Alam e McNabola (2014), trata-se de um processo de tomada de decisão que abrange três níveis: estratégico (como manutenção do veículo), tático (planejamento da viagem) e operacional (comportamento ao volante). Já outras abordagens classificam o conceito em duas vertentes principais: orientada por regras e orientada por otimização (XU et al., 2021). A abordagem baseada em regras consiste em diretrizes qualitativas amplas e de fácil aplicação pelos motoristas, mas com resultados variáveis conforme o ambiente de tráfego e o perfil do condutor. Por outro lado, a vertente baseada em otimização busca determinar, por meio de algoritmos, o comportamento de condução mais eficiente com base em informações de tráfego e geográficas em tempo real, prometendo melhores resultados em termos de economia.

Diversos estudos têm quantificado os impactos positivos do eco-driving. Para veículos com motores de combustão interna, o estilo de condução pode influenciar o consumo de combustível em até 15%–25% (kamal2011ecological). No caso de veículos híbridos, essa diferença pode chegar a 50% (DU, 2017), enquanto para veículos elétricos, a redução no consumo energético pode alcançar cerca de 25% (GÜNTHER; KACPERSKI; KREMS, 2020). Há também evidências de que alterações no estilo de condução podem melhorar o consumo e reduzir emissões em até 40% (MANZONI et al., 2010; MIERLO et al., 2004).

Além da prática em si, é fundamental compreender como medir ou incentivar comportamentos de direção ecológica. Os métodos de avaliação dividem-se, em geral, em abordagens qualitativas e quantitativas (XU et al., 2021). No campo qualitativo, destaca-se o reconhecimento do estilo de condução. Já na avaliação quantitativa, métricas como consumo de energia

e ocorrência de eventos específicos de direção são utilizadas.

Nesse sentido, surgem propostas sofisticadas de pontuação ecológica. Um exemplo é o estudo de [Xu et al. \(2021\)](#), que utiliza dados de GPS de motoristas reais para atribuir pontuações com base nas emissões de CO e consumo de energia, considerando as características específicas de cada veículo. Para veículos elétricos e híbridos, calcula-se uma eficiência de combustível equivalente. Uma segunda versão do modelo considera ainda as condições de tráfego, comparando viagens em contextos semelhantes. Com isso, o sistema se torna mais justo, evitando penalizar motoristas que trafegam em congestionamentos ou premiar de forma indevida quem conduz em vias livres com velocidades medianas.

A aplicação prática do eco-driving pode ocorrer por meio de treinamentos ou dispositivos embarcados de feedback. Treinamentos são relativamente simples de implementar, mas tendem a perder efeito com o tempo. Já os dispositivos, que fornecem informações ao motorista em tempo real por meio de sinais visuais, sonoros ou táteis, apresentam maior potencial de impacto, embora questões de segurança e aceitação devam ser consideradas ([XU et al., 2021](#)).

## 2.2 Coleta de Dados Veiculares

A análise do comportamento de motoristas e da eficiência operacional dos veículos depende diretamente da qualidade e diversidade dos dados coletados. Diversos dispositivos e métodos têm sido utilizados na literatura para essa finalidade, variando em custo, confiabilidade, granularidade e aplicabilidade.

Entre os dispositivos mais comuns está o GPS, amplamente utilizado para rastreamento e inferência de padrões de direção. Apesar de sua popularidade, o GPS apresenta limitações quando se trata de capturar informações diretamente relacionadas à eficiência energética, uma vez que suas correlações com o consumo são geralmente indiretas ([SINGH; KATHURIA, 2021](#)). Já os dispositivos OBD (On-Board Diagnostics) oferecem dados precisos e confiáveis sobre o motor e o desempenho do veículo, sendo amplamente empregados em estudos que exigem precisão. Por outro lado, sensores embarcados em smartphones, como acelerômetros e giroscópios, têm ganhado destaque devido ao seu baixo custo e ampla disponibilidade. No entanto, enfrentam desafios quanto à integridade dos dados, interferências do ambiente e limitações de hardware ([SINGH; KATHURIA, 2021](#)).

Além dos sensores, diversos métodos de coleta e avaliação de comportamento de condutores foram discutidos por [Ghatee e Eftekhari \(2018\)](#), incluindo questionários autodeclarados, simuladores de direção, avaliação por especialistas, registradores embarcados e sensores de smartphones. Cada um desses métodos possui vantagens e desvantagens específicas. Por exemplo, questionários são de baixo custo, mas altamente sujeitos à memória e percepção do motorista; simuladores permitem a simulação de cenários críticos, mas não garantem realismo; enquanto sensores embarcados fornecem dados em tempo real, porém com custo elevado e possibilidade de manipulação.

Já o estudo de [Bouhsissin, Sael e Benabbou \(2023\)](#) apresenta uma análise quantitativa

da prevalência dos diferentes tipos de sensores utilizados em trabalhos recentes. De acordo com os autores, simuladores são os dispositivos mais empregados (25% dos estudos analisados), seguidos por câmeras (17%), GPS (13%), sensores de smartphones (9%) e acelerômetros (9%). Outras fontes relevantes incluem giroscópios, sensores de orientação, OBDII, questionários, EEG, ECG, radar, magnetômetro, observadores humanos e sensores de condutância da pele (EDA), cada um representando pequenas fatias do total de estudos.

Em síntese, a escolha do método e dispositivo de coleta de dados está diretamente relacionada ao objetivo da pesquisa, ao orçamento disponível e à necessidade de precisão. Métodos híbridos e sistemas integrados têm se mostrado cada vez mais promissores, ao combinar as vantagens de diferentes tecnologias para fornecer uma visão mais abrangente e acurada do comportamento veicular.

### 2.3 Dados da Rede CAN

A Controller Area Network (CAN) é um protocolo de comunicação serial amplamente utilizado na indústria automotiva, permitindo a troca eficiente e segura de dados entre diferentes unidades de controle eletrônico (ECUs), sensores e atuadores do veículo ([Robert Bosch GmbH, 1991](#)). Com taxas de transmissão de até 1 Mbit/s, a rede CAN possibilita o controle distribuído em tempo real, sendo integrada tanto em sistemas críticos como o controle do motor e freios ABS quanto em funções auxiliares, como acionamento de janelas e luzes.

Estudos recentes demonstram o potencial dos dados provenientes da rede CAN para análise do comportamento veicular e classificação de estilos de direção. Fugiglando et al. ([FUGIGLANDO et al., 2017](#)) realizaram uma das primeiras análises em larga escala utilizando dados da CAN, coletando 2418 sinais distintos durante 55 dias com 64 motoristas em condições reais e não controladas. O estudo evidenciou a viabilidade de capturar padrões de direção a partir dos dados da rede CAN em ambientes urbanos.

Além disso, Park et al. ([PARK; KIM, 2019](#)) utilizaram dados coletados via OBD-II com o scanner CarbigSP para identificar motoristas com base em seu estilo de condução, mostrando o potencial da CAN para aplicações em segurança veicular, como prevenção de furtos. Dados como posição do pedal do acelerador, velocidade, rotação do motor e pressão do pedal de freio foram registrados com alta resolução temporal (1 Hz).

Almeida ([ALMEIDA, 2023](#)) também explorou a CAN em um estudo com caminhões comerciais, coletando dados ao longo de três meses para classificar o comportamento de motoristas e detectar condução agressiva. A pesquisa mostrou que, apesar das variações entre modelos, há informações comuns — como velocidade e aceleração — que permitem a generalização das análises para diferentes veículos.

No Brasil, trabalhos como os de Vernizzi ([VERNIZZI, 2024](#)) e Cavalcante ([CAVALCANTE, 2018](#)) destacam o desenvolvimento de soluções de baixo custo para aquisição de dados da rede CAN utilizando microcontroladores como o ESP32. Esses sistemas acessam informações via porta OBD-II, armazenando dados localmente em cartão SD ou transmitindo-os

via internet para análise posterior. Essa abordagem torna a coleta de dados CAN mais acessível para pesquisas acadêmicas e aplicações comerciais.

Dentre as principais vantagens do uso de dados da rede CAN estão a alta frequência de amostragem, a padronização parcial dos sinais, a não intrusividade na condução do motorista e a riqueza de informações sobre o funcionamento do veículo. No entanto, as limitações incluem a variação entre fabricantes quanto à codificação de sinais, a necessidade de hardware específico (como interfaces OBD-II e microcontroladores programáveis) e o desafio de mapear corretamente os identificadores (IDs) da CAN para sinais interpretáveis.

## 2.4 Classificação de Estilos de Direção

A classificação de estilos de direção é uma etapa fundamental para a análise comportamental de motoristas, especialmente em contextos que envolvem segurança viária e eficiência energética. A literatura propõe diversas formas de categorizar os estilos de condução, variando em número de categorias, critérios utilizados e contexto de aplicação (como ambientes urbanos, rodoviários ou simulados).

De forma geral, a maioria dos estudos adota uma classificação em três grupos principais: agressivo, normal e cauteloso (DÖRR; GRABENGISSER; GAUTERIN, 2014; HIGGS; ABBAS, 2013; XU et al., 2015). Essa abordagem busca representar um espectro de comportamentos que varia desde manobras arriscadas e impulsivas até condução defensiva e previsível.

Algumas pesquisas propõem classificações mais detalhadas. Em ambientes simulados, por exemplo, (BÄR et al., 2011) identificaram cinco estilos distintos: agressivo, ansioso, econômico, entusiasta (keen) e tranquilo (sedate). Essa taxonomia mais rica permite uma análise mais fina de perfis psicológicos e hábitos de direção.

Outros estudos utilizaram lógica fuzzy para classificar os motoristas com base em dados de aceleração, estabelecendo categorias como abaixo do normal, normal, agressivo e muito agressivo (ALJAAFREH; ALSHABATAT; AL-DIN, 2012). Essa abordagem é útil por lidar com a incerteza e a subjetividade inerentes à definição de estilos de direção.

Já em contextos mais práticos, com sensores embarcados em smartphones, há estudos que optaram por simplificar a classificação em apenas dois grupos: agressivo e não agressivo, facilitando a detecção de padrões em tempo real e aplicações em larga escala (JOHNSON; TRIVEDI, 2011).

## 2.5 Eventos Indicadores de Comportamento Agressivo

A identificação de eventos de direção agressiva é fundamental para avaliar o comportamento do condutor e seu impacto tanto na segurança quanto na eficiência energética. Estudos indicam que variáveis como velocidade, aceleração, frenagem, localização, quilometragem e variações temporais estão entre os principais parâmetros para avaliação de risco de acidentes (SINGH; KATHURIA, 2021).

Para a detecção de comportamentos agressivos, diversos eventos são monitorados e analisados, tais como:

- **Frenagens bruscas**, acelerações rápidas e curvas fechadas, frequentemente associadas a mudanças repentinas no controle do veículo (FAZEEN et al., 2012; DAI et al., 2010; VAIANA et al., 2014; KNAPPE et al., 2007).
- **Mudança de faixa sem sinalização**, cujo grau de frequência e intensidade pode indicar imprudência (JAMES, 2009; VAIANA et al., 2014).
- **Velocidade excessiva e variações rápidas de velocidade**, que estão entre os principais preditores de comportamento agressivo e de aumento no consumo de combustível (JAMES, 2009; KIM; PARK; LEE, 2021).
- **Direção em horários noturnos**, que potencialmente eleva o risco de acidentes, dependendo da localização e da intensidade do tráfego (SINGH; KATHURIA, 2021).

Os estudos também utilizam medidas como aceleração lateral e longitudinal (ALJAFREH; ALSHABATAT; AL-DIN, 2012), e a derivada da aceleração (conhecida como *jerk*) (MURPHEY; MILTON; KILIARIS, 2009), para indicar variações bruscas no movimento do veículo, que são característicos da condução agressiva.

Além dos parâmetros de dinâmica veicular, outros indicadores extraídos da rede CAN (Controller Area Network) têm sido utilizados, como pressão do pedal de freio, posição do pedal do acelerador, rotação do motor (RPM), Velocidade do veículo, ângulo e momento do volante e aceleração frontal e lateral (FUGIGLANDO et al., 2017).

A construção de índices compostos para classificar a agressividade também tem considerado variáveis como: taxa de inércia, violação de indicadores de mudança de faixa, troca de marchas em baixa rotação, e gradiente do pedal do acelerador (KIM; PARK; LEE, 2021).

Esses eventos e variáveis, quando combinados, oferecem uma base sólida para a classificação automatizada de estilos de direção, podendo alimentar modelos preditivos, sistemas de pontuação e intervenções de feedback em tempo real.

## 2.6 Algoritmos de Classificação

Com base no estudo sistemático conduzido por (BOUHSISSIN; SAEL; BENABBOU, 2023), observa-se uma ampla aplicação de algoritmos de aprendizado de máquina (ML), aprendizado profundo (DL) e técnicas estatísticas na classificação de estilos de direção. Segundo o estudo, 60% dos trabalhos utilizam algoritmos de ML, 34,87% DL, e apenas 5,13% adotam métodos estatísticos. Entre os algoritmos mais recorrentes destacam-se Support Vector Machine (SVM), Logistic Regression (LR), Random Forest (RF), K-Nearest Neighbors (KNN), Decision Tree (DT), Adaptive Boosting (AdaBoost) e Bayesian Networks (BN) no grupo de aprendizado de máquina (ML). Enquanto isso, Long Short-Term Memory (LSTM), Convolutional Neural Networks (CNN), Artificial Neural Networks (ANN), Recurrent Neural Networks (RNN), Deep Neural Networks (DNN), autoencoders e outras variantes são os mais empregados entre os métodos baseados em redes neurais profundas. O algoritmo LSTM se sobressai no conjunto de



dados UAH-DriveSet, alcançando 99,49% de F1-score para as categorias agressivo, sonolento e normal, enquanto o RF obteve até 98,5% de concordância no conjunto SHRP2, ao classificar comportamentos como uso do celular, alimentação e higiene ao volante. De forma geral, o LSTM lidera em uso (17,14%), seguido de SVM (14,29%) e RF (11,43%).

O estudo também mostra que algoritmos de ML continuam sendo os mais utilizados, representando 51,43% das aplicações sobre datasets, com DL somando 42,86%. Quando se consideram as diferentes fontes de dados, SVM aparece como o mais recorrente (19,60%), principalmente em dados de sensores de smartphone e simuladores. A acurácia dos modelos varia conforme o conjunto de dados e abordagem: de 90% com SVM em classificações binárias (comportamento perigoso vs. seguro) a 95% com GRU, e até 100% de acurácia com SVM. Os critérios de avaliação mais frequentes são F1-score, acurácia e concordância entre observações.

Complementarmente ao estudo de ([BOUHSISSIN; SAEL; BENABBOU, 2023](#)), outras abordagens de classificação de comportamento de motoristas também foram exploradas na literatura. Entre os métodos de perfilamento, destaca-se o uso da análise de clusters para categorizar motoristas, enquanto técnicas como o Processo de Hierarquia Analítica (AHP) têm sido criticadas por sua suscetibilidade a incertezas e baixa confiabilidade ([SINGH; KATHURIA, 2021](#)). Métodos estatísticos como o Controle Estatístico de Processos (SPC) também são empregados, além da análise do perfil de jerk — variações abruptas na aceleração — como proposta por ([SINGH; KATHURIA, 2021](#)), que utiliza informações estatísticas do jerk combinadas com o tipo de via e nível de congestionamento para classificar o estilo de condução.

No campo da lógica fuzzy, ([MURPHEY; MILTON; KILIARIS, 2009](#)) propuseram um sistema de inferência fuzzy em tempo real que utiliza como entradas o valor normativo de aceleração longitudinal e lateral, além da velocidade, permitindo a classificação instantânea de estilos de direção a baixo custo computacional. Já ([ALJAAFREH; ALSHABATAT; AL-DIN, 2012](#)) desenvolveram um sistema híbrido baseado em Transformada Wavelet Discreta (DWT) e Sistema de Inferência Neuro-Fuzzy Adaptativo (ANFIS) que combina os resultados de múltiplos ANFIS via técnicas de fusão de decisão, permitindo maior robustez na detecção de padrões complexos de condução.

## 2.7 Aprendizado Federado

O Aprendizado Federado (Federated Learning – FL) tem se consolidado como uma solução eficaz para o desenvolvimento de modelos de aprendizado de máquina em cenários com alta fragmentação de dados, especialmente em contextos regulatórios que priorizam a privacidade dos indivíduos. Nessa abordagem distribuída, os dados permanecem nos dispositivos locais e apenas os parâmetros dos modelos são compartilhados entre as entidades participantes, garantindo que a privacidade seja preservada ao longo de todo o processo [Ramos et al. \(2021\)](#).

No setor automotivo, o FL se mostra particularmente promissor, pois permite o treinamento colaborativo de modelos entre veículos conectados e autônomos (CAVs), sem que haja exposição direta das informações sensíveis dos motoristas. Estão sendo exploradas aplicações



como a classificação de ações de motoristas, com resultados promissores na preservação da privacidade durante o treinamento dos modelos [Chen, Torstensson e Englund \(2020\)](#). Técnicas como FedAvg e suas variantes são comumente utilizadas na agregação dos modelos locais, enquanto estratégias adicionais — como privacidade diferencial e blockchain — são investigadas para lidar com desafios típicos desse cenário, como dados não independentes e identicamente distribuídos (não-IID), limitações computacionais e ameaças à segurança [Chellapandi et al. \(2023\)](#).

## 2.8 Sistemas de Feedback

A mudança de comportamento de motoristas em direção a uma condução mais segura e eficiente tem sido objeto de diversos estudos que investigam a eficácia de sistemas de feedback. Esses sistemas, ao fornecerem informações sobre o estilo de direção, buscam incentivar práticas como o eco-driving e reduzir comportamentos agressivos.

Embora medidas de fiscalização e punição possam ter algum impacto, há consenso de que abordagens educativas e preventivas são mais eficazes a longo prazo. Isso porque comportamentos como acelerações bruscas com altas rotações, apesar de não constituírem infrações formais, ainda representam riscos ao veículo e ao meio ambiente. Assim, o foco em ferramentas que promovam a consciência e a autorregulação é essencial ([MIKULÍČ; BOŠKOVIĆ; ZOVAK, 2020](#)).

Dentre essas ferramentas, destacam-se os sistemas de feedback visual, sonoro e tátil, que podem ser entregues em tempo real ou posteriormente, por meio de relatórios ou dashboards. Estudos demonstram que o feedback em tempo real é especialmente atrativo aos motoristas, pois permite correções imediatas durante a condução ([STEPHENS, 2022](#)).

Soluções baseadas em gamificação têm ganhado destaque. Uma revisão sistemática analisou 39 estudos que exploraram o uso de elementos lúdicos, como pontuações, recompensas, rankings e visualizações criativas — como emojis ou árvores que crescem conforme a performance melhora. Esses sistemas, muitas vezes implementados em aplicativos móveis, mostraram resultados promissores, como a redução de velocidade e o aumento da eficiência no consumo de combustível. O aplicativo "Coastmaster", por exemplo, foi citado por gerar melhorias mensuráveis em direção econômica ([STEPHENS, 2022](#)).

Em um estudo prático com motoristas de ônibus urbanos, a implementação de um display intuitivo com pontuação de eco-driving resultou em uma economia de combustível de 12,1%. A pontuação, construída com base em múltiplos índices (como frenagem, aceleração, entre outros), foi calculada com técnicas de aprendizado de máquina, e sua relevância foi explicada com ferramentas de interpretabilidade do modelo. A visualização direta do score, que ia até 100, permitia aos condutores compreenderem seu desempenho e adaptarem seu comportamento em tempo real ([KIM; PARK; LEE, 2021](#)).

Apesar dos avanços, os estudos enfrentam limitações, como tamanho reduzido de amostras e falta de rigor estatístico. Ainda assim, os resultados sugerem que sistemas de

feedback, especialmente quando personalizados, intuitivos e integrados com elementos motivacionais, têm grande potencial para melhorar tanto a segurança quanto a sustentabilidade da mobilidade.

### 3 METODOLOGIA

Considerando o impacto significativo do comportamento de condução no consumo de energia, nas emissões veiculares e na segurança viária, torna-se crucial desenvolver métodos eficazes para classificar e analisar os estilos de condução. Um dos principais desafios nessa área é a ausência de dados rotulados, especialmente quando se trabalha com conjuntos de dados de telemetria coletados sem rotulagem prévia. A rotulagem manual, embora precisa, é altamente impraticável para grandes volumes de dados devido ao tempo e esforço extensivos necessários. Conforme destacado em [Bouhsissin, Sael e Benabbou \(2023\)](#), essa limitação impulsiona a necessidade de métodos automáticos de rotulagem que sejam capazes de categorizar o comportamento de condução de forma eficiente e consistente.

A rotulagem automática é geralmente realizada por meio de técnicas de aprendizado de máquina, métodos baseados em heurísticas ou pela combinação de ambos. Dentre essas abordagens, os algoritmos de agrupamento — em especial o K-Means ([LLOYD, 1982](#)) — são frequentemente adotados devido à sua simplicidade e eficácia na identificação de padrões sem a necessidade de rótulos prévios. No entanto, muitos estudos anteriores utilizam um conjunto limitado de variáveis ou focam em aspectos muito específicos do comportamento de condução, o que restringe a generalização e a abrangência da análise.

Neste contexto, este trabalho se propõe a desenvolver e avaliar uma metodologia para a rotulagem de comportamentos de condução utilizando o algoritmo de agrupamento K-Means aplicado a dados de telemetria automotiva coletados da rede CAN (Controller Area Network). A metodologia combina múltiplas abordagens visando alcançar uma caracterização mais abrangente e robusta dos estilos de condução. Diferentemente da maioria dos trabalhos existentes — que frequentemente dependem de um conjunto restrito de sinais ou aplicam técnicas isoladas —, este estudo integra o agrupamento não supervisionado com três métodos consolidados na literatura: (i) modelos de lógica fuzzy baseados nas acelerações lateral e longitudinal; (ii) análise estatística utilizando jerk (derivada da aceleração) para capturar variações dinâmicas no comportamento de condução; e (iii) regras determinísticas baseadas em limiares empíricos para variáveis-chave como rotação do motor (RPM), posição do acelerador e ângulo do volante. Esta abordagem integrada permite a identificação de padrões de condução sob múltiplas perspectivas, suprimindo lacunas da pesquisa anterior e viabilizando uma rotulagem mais ampla e confiável do comportamento dos condutores.

Ao analisar como essas metodologias se alinham, se complementam ou divergem, o estudo busca não apenas comparar seus resultados, mas também utilizá-los como ferramenta para caracterizar e validar os agrupamentos gerados pelo K-Means. Esse processo, em última instância, viabiliza uma rotulagem robusta dos estilos de condução — calmo, normal e agressivo —, proporcionando uma compreensão ampla dos padrões de comportamento dos motoristas e reforçando o potencial do aprendizado não supervisionado para essa aplicação.

[ADICIONAR PROXIMAS SEÇÕES] Texto introdutório explicando o objetivo do capítulo: descrever a abordagem metodológica utilizada no desenvolvimento do trabalho. Aqui deve ser explicado o processo completo, desde a obtenção e tratamento dos dados até o desenvolvimento do algoritmo e dos testes com hardware. Pode-se também apresentar um fluxograma geral com as etapas.

### 3.1 Rotulagem dos Dados (Data Labeling)

Este trabalho propõe uma metodologia para rotulagem e análise de estilos de condução com base em dados veiculares. Inicialmente, foi realizada a seleção de variáveis relevantes de uma base pública de dados obtidos via barramento CAN, seguida da extração de variáveis derivadas, como jerk, aceleração normalizada e deflexão do volante, que enriquecem a análise do comportamento de direção. Em seguida, aplicou-se o algoritmo K-Means para agrupar os dados em padrões de condução sem a necessidade de rótulos prévios.

Para interpretar os clusters formados, os dados também foram classificados por três abordagens supervisionadas inspiradas na literatura: uma baseada em regras determinísticas, outra utilizando lógica fuzzy e uma terceira fundamentada na análise estatística do jerk. Foi então proposto um método para consolidar essas classificações, agrupando os segmentos com base na concordância de pelo menos duas das três abordagens. A análise das médias das variáveis permitiu compreender as características de cada cluster e validar a coerência dos grupos encontrados, possibilitando a atribuição de perfis de condução como calmo, normal e agressivo.

#### 3.1.1 Coleta de Dados

O conjunto de dados utilizado neste trabalho foi originalmente coletado por Kwak, Woo e Kim (2016), a partir de um ambiente real de condução, com o objetivo de capturar variáveis que não poderiam ser completamente representadas em simulações. Para isso, foi utilizada uma combinação entre o sistema OBD-II (On Board Diagnostics) e uma ferramenta de captura para extração de características, permitindo extrair dados diretamente da rede CAN dos veículos.

A coleta compreendeu cerca de 23 horas de condução, totalizando aproximadamente 46 km de percurso (ida e volta) entre a Universidade da Coreia e o Estádio da Copa do Mundo em Sangam. Participaram da coleta 10 motoristas diferentes, rotulados de A a J, sendo que os dados foram registrados em intervalos de um segundo ao longo das viagens. O veículo utilizado pertence a um modelo recente da KIA Motors Corporation, e, ao todo, foram extraídas 51 variáveis distintas associadas ao comportamento de condução.

Entre os diversos sinais transmitidos pela rede CAN do veículo, foram selecionadas apenas as variáveis mais relevantes para as análises deste trabalho, a fim de reduzir a dimensionalidade e o ruído da base de dados. As colunas escolhidas refletem diretamente o

comportamento de condução, sendo:

- **Fuel\_consumption**: valor instantâneo relacionado ao consumo de combustível;
- **Throttle\_position\_signal**: posição relativa do pedal do acelerador, obtida por meio do sensor de posição da borboleta;
- **Engine\_speed**: rotação do motor, em RPM (rotações por minuto);
- **Vehicle\_speed**: velocidade instantânea do veículo;
- **Acceleration\_speed\_Longitudinal**: aceleração no eixo longitudinal do veículo;
- **Acceleration\_speed\_Lateral**: aceleração lateral, associada à realização de curvas;
- **Steering\_wheel\_angle**: ângulo de esterçamento do volante.

Sinais como pedais e volante refletem diretamente as ações do condutor, enquanto variáveis como velocidade, rotação do motor e acelerações expressam sensações perceptíveis durante a condução. Esses parâmetros podem indicar padrões de direção específicos, como tendência a acelerar bruscamente, conduzir em alta velocidade ou realizar curvas agressivas.

Uma coluna de identificação única (ID) foi adicionada para cada amostra do conjunto. Além disso, a coluna de tempo foi utilizada para segmentar o conjunto de dados em sessões independentes — denominadas *runs* —, correspondentes a cada viagem registrada. Essa separação foi baseada em reinicializações do índice temporal. A extração de atributos foi realizada iterativamente por *run*.

### 3.1.2 Extração de características (Features)

Foram extraídas variáveis adicionais relevantes para a análise do comportamento do condutor.

#### 3.1.2.1 Aceleração normalizada (*acc\_norm*)

A aceleração normalizada é uma métrica derivada da composição vetorial das acelerações longitudinal e lateral do veículo, representando a força *g* total experimentada em cada instante. De acordo com [Aljaafreh, Alshabat e Al-Din \(2012\)](#), sensores acelerômetros de dois eixos podem ser utilizados para capturar essa grandeza, permitindo identificar padrões de direção ao comparar diferentes estilos de condução, como partidas e frenagens bruscas. O estudo mostra que a aceleração combinada é um bom indicador para classificar o desempenho do condutor.

A norma da aceleração em um instante  $n$  é calculada conforme (1).

$$acc\_norm(n) = \sqrt{Accel_{long}^2(n) + Accel_{lat}^2(n)} \quad (1)$$

Essa métrica sintetiza os efeitos dinâmicos associados à movimentação do veículo em curvas, acelerações e frenagens, e é particularmente útil para detectar comportamentos agressivos na condução.

### 3.1.2.2 Deflexão do volante

O estudo de [Karrouchi et al. \(2023\)](#) realizou testes práticos com motoristas para analisar o tempo necessário de variação no ângulo de direção em diferentes contextos de direção. Os resultados mostram que a deflexão do volante é uma métrica significativa para distinguir estilos de condução, sendo utilizada como parâmetro na classificação do comportamento do condutor.

A deflexão do volante foi definida como a variação absoluta entre valores consecutivos do ângulo de direção (2), em que  $\Delta a$  representa a diferença no ângulo de direção e  $\Delta t$  o intervalo de tempo entre duas medições sucessivas.

$$K = \frac{\Delta a}{\Delta t} = \frac{|a_2 - a_1|}{t_2 - t_1} \quad (2)$$

### 3.1.2.3 Jerk

Jerk é definido como a taxa de variação da aceleração, ou seja, a derivada de segunda ordem da velocidade em relação ao tempo. Essa métrica é particularmente relevante para a análise do conforto e da segurança na condução, pois mudanças bruscas na aceleração (valores elevados de jerk) podem causar desconforto aos passageiros e aumentar o risco de acidentes ([MURPHEY; MILTON; KILIARIS, 2009](#); [ALMEIDA, 2023](#)).

Neste trabalho, o jerk foi estimado por meio da segunda diferença da velocidade do veículo (convertida para m/s), conforme (3).

$$J(t) = \frac{d^2v(t)}{dt^2} \quad (3)$$

Inspirados na abordagem de [Murphey, Milton e Kiliaris \(2009\)](#), foi utilizado o coeficiente de variação  $\gamma$  como métrica, definido como a razão entre o desvio padrão do jerk ( $SD_J$ ), calculado dentro da janela móvel, e o valor médio de referência ( $J_{ref}$ ), que corresponde ao jerk do estilo de condução normal no tipo de via em que o motorista se encontra.

Para fins de classificação, o estilo de condução do motorista no instante atual  $t_e$  é classificado com base nas seguintes características do jerk, extraídas dentro do intervalo de tempo  $t \in [(t_e - \omega), t_e]$ , onde  $t_e$  representa o instante atual e  $\omega$  é o tamanho da janela de observação. Para cada instante de tempo  $t_e$ , o desvio padrão foi calculado dentro de uma janela móvel de 10 segundos.

$$\gamma = \frac{SD_J}{J_{ref}} \quad (4)$$

Como os dados foram coletados em ambientes reais e não controlados, não foi possível associar cada segmento de trajeto a um tipo específico de via. Assim, foi adotado o valor médio global de jerk estimado por [Almeida \(2023\)](#), igual a  $0,2732 \text{ m/s}^3$ , como referência para normalização.

### 3.1.3 K-means

Após a obtenção das features adicionais, procedeu-se com a análise de agrupamento utilizando o algoritmo K-Means, com o objetivo de identificar padrões emergentes nos dados de direção.

Foram removidas todas as entradas em que a velocidade apresentava valor igual a zero, por não representarem efetivamente trechos de condução.

Para a análise de clusters, foram selecionadas as seguintes variáveis numéricas:

- **Fuel\_consumption**: valor instantâneo relacionado ao consumo de combustível;
- **Throttle\_position\_signal**: posição relativa do pedal do acelerador, obtida por meio do sensor de posição da borboleta;
- **Engine\_speed**: rotação do motor, em RPM (rotações por minuto);
- **Vehicle\_speed**: velocidade instantânea do veículo;
- **Acceleration\_norm**: composição vetorial das acelerações longitudinal e lateral do veículo;
- **Deflection\_angle**: variação absoluta entre valores consecutivos do ângulo de direção.

Estas variáveis foram escolhidas por representarem aspectos distintos, porém complementares, do comportamento de condução.

Os dados foram normalizados utilizando Z-score (subtração da média e divisão pelo desvio padrão), garantindo que todas as variáveis contribuíssem igualmente para o cálculo das distâncias no espaço multidimensional do K-Means.

O algoritmo K-Means foi aplicado com  $k = 3$  clusters e 10 replicações, buscando garantir maior robustez e minimizar o risco de convergência a mínimos locais. A escolha de três clusters foi fundamentada em análises exploratórias prévias, estudos da literatura ([FUGIGLANDO et al., 2017](#)) e na coerência com o número de classes utilizado nas outras abordagens de classificação.

### 3.1.4 Análise Cruzada com Classificações Independentes

Com os dados previamente agrupados, tornou-se necessário definir rótulos representativos para cada cluster. Para isso, foram empregados três sistemas independentes de classificação, possibilitando uma análise cruzada entre os agrupamentos obtidos por K-Means e as classes atribuídas por métodos supervisionados. Essa abordagem permitiu avaliar o grau de alinhamento ou divergência entre técnicas supervisionadas e não supervisionadas, além de evidenciar características predominantes em cada grupo.

#### 3.1.4.1 Classificação Fuzzy

Seguindo a proposta de [Aljaafreh, Alshabat e Al-Din \(2012\)](#), foi implementado um Sistema de Inferência Fuzzy (FIS) com duas variáveis de entrada: aceleração combinada (ou normalizada) e velocidade do veículo. O sistema classifica as amostras em três categorias: Calmo, Normal e Agressivo. Ambas as variáveis refletem o comportamento de velocidade, tanto

em trechos retilíneos quanto em curvas, indicando tendências como excesso de velocidade ou acelerações bruscas.

A Fig. 1 apresenta a série temporal da velocidade e da aceleração normalizadas para uma viagem do motorista A. Já a Fig. 2 mostra a relação entre velocidade, aceleração e o grau de pertinência calculado pelo sistema fuzzy, em que o azul escuro representa uma condução calma e o vermelho escuro, uma condução agressiva.




Figura 1 – Série temporal da velocidade e aceleração normalizadas para uma viagem do motorista A.

#### 3.1.4.2 Classificação Determinística

Inspirado na abordagem de [Karrouchi et al. \(2023\)](#), foi realizada uma classificação binária baseada em regras simples definidas por limiares em três variáveis:

- **Posição do pedal do acelerador:**

- Normal:  $\leq 38$
- Agressivo:  $> 38$

- **RPM (rotações por minuto):**

- Normal:  $\leq 3300$
- Agressivo:  $> 3300$

- **Deflexão do volante:**

- Normal:  $< 355$
- Agressivo:  $\geq 355$






Figura 2 – Relação entre velocidade, aceleração e grau de pertinência fuzzy, onde azul escuro indica condução calma e vermelho escuro, condução agressiva.

Esses parâmetros refletem situações de uso intensivo do motor, pressionamento acentuado do pedal e movimentos bruscos do volante, frequentemente associados a ultrapassagens, mudanças de faixa repentinas ou curvas fechadas.

A Fig. 3 apresenta a relação entre as variáveis RPM, posição do pedal do acelerador, deflexão do volante, aceleração e o score de agressividade calculado pelo classificador determinístico. Esse score foi obtido por meio de uma média ponderada das variáveis normalizadas de posição do acelerador, rotação do motor e deflexão do volante, sendo atribuídos pesos iguais de 0,33 para cada uma. As normalizações foram realizadas considerando os valores máximos definidos para cada variável — 100 para a posição do pedal, 6000 para RPM e 500 para deflexão.

Cada variável contribui para o score apenas quando ultrapassa um limiar, definido com base em critérios de domínio: 38 para a posição do pedal, 3300 para RPM e 355 para deflexão. Assim, o score assume valor zero quando nenhuma dessas variáveis ultrapassa os respectivos limiares, classificando a amostra como “Normal”. Caso contrário, qualquer contribuição diferente de zero resulta na classificação como “Agressivo”.

A visualização permite observar como a combinação dessas variáveis influencia diretamente na definição do perfil de condução no modelo determinístico, destacando as regiões do espaço de variáveis que mais concentram os comportamentos classificados como agressivos.

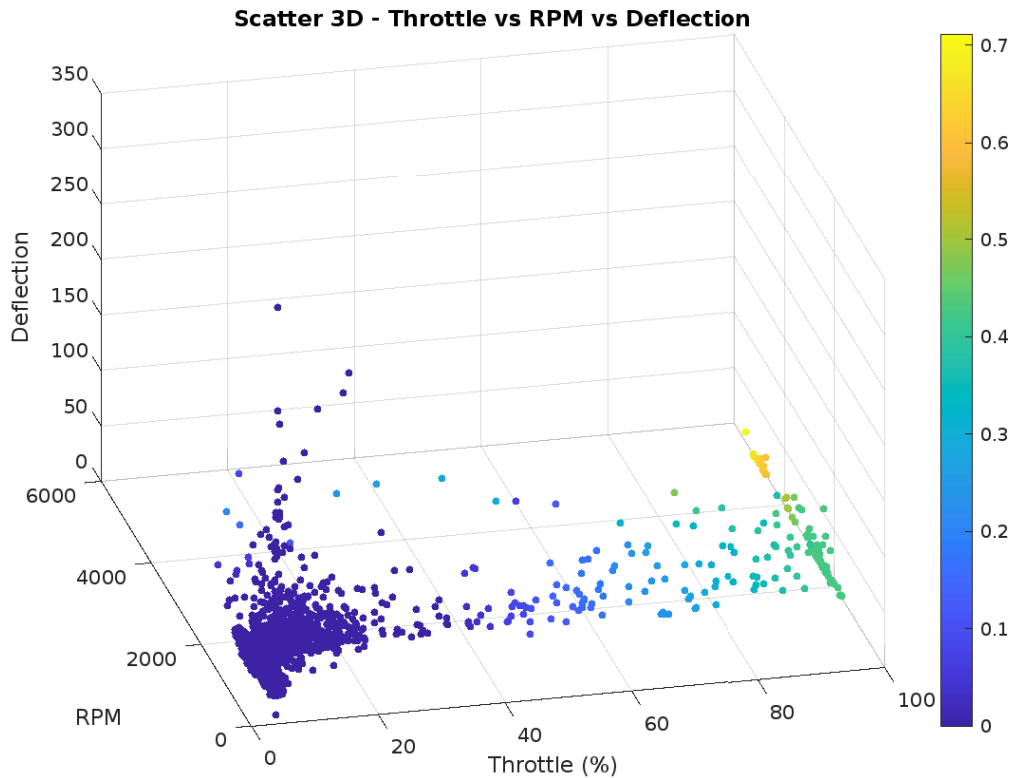


Figura 3 – Relação entre RPM, pedal do acelerador, deflexão do volante e aceleração no cálculo do score de agressividade do classificador determinístico.

#### 3.1.4.3 Classificação por Jerk

Com base na métrica  $\gamma$ , definida pela razão entre o desvio padrão do jerk ( $SD_J$ ) e um valor de referência ( $J_{ref}$ ), o estilo de condução foi classificado conforme os intervalos sugeridos por [Murphey, Milton e Kiliaris \(2009\)](#):

- **Calmo:**  $\gamma < 0.5$
- **Normal:**  $0.5 \leq \gamma < 1$
- **Agressivo:**  $\gamma \geq 1$

A Fig. 4 apresenta uma série temporal da velocidade e dos resultados de classificação utilizando o método baseado em jerk, aplicado a uma janela deslizante de aproximadamente 10 segundos sobre um trecho de cerca de 200 segundos da condução de um motorista. A cada instante  $t$ , a classificação é exibida apenas quando há uma mudança em relação à classe anterior, proporcionando uma visualização mais limpa das transições de comportamento. É possível observar como variações bruscas de aceleração, representadas pelo jerk, estão diretamente associadas às mudanças nos perfis de condução ao longo do trajeto.

#### 3.1.4.4 Agrupamento por Concordância de Classificações

Com base nas classificações obtidas pelos três métodos, foi realizada uma categorização qualitativa das amostras segundo a concordância entre os classificadores. A cada amostra foi atribuído um identificador de grupo (1, 2 ou 3), com base nas seguintes combinações:




Figura 4 – Série temporal da velocidade e da classificação do estilo de condução utilizando o método baseado em jerk, com janelas de aproximadamente 10 segundos, ao longo de 200 segundos de uma viagem.

- **Grupo 1 (Calmo):** Determinístico = Normal, Fuzzy = Calmo, Jerk = Calmo
- **Grupo 2 (Normal):** Todos os três classificadores indicam "Normal"
- **Grupo 3 (Agressivo):** Todos os três classificadores indicam "Agressivo"

O agrupamento foi considerado válido quando ao menos duas das três classificações apresentaram concordância. Nos casos sem nenhuma convergência entre os métodos, a amostra foi atribuída ao **Grupo 0**. Para essas instâncias, a classificação final foi inferida por validação cruzada com os clusters obtidos anteriormente.

### 3.1.5 Resultados da Rotulagem

Nesta seção, são apresentados os principais resultados obtidos a partir da análise dos dados de condução, considerando tanto os métodos de classificação utilizados quanto os agrupamentos gerados.

A Tabela 1 apresenta um resumo estatístico das principais variáveis analisadas, segmen-

tadas por grupos definidos a partir da concordância entre os três classificadores independentes (fuzzy, determinístico e jerk). Essa tabela permite visualizar padrões médios de comportamento associados aos perfis de condução identificados.

Tabela 1 – Resumo estatístico por grupo com médias das variáveis selecionadas

Grupo	Contagem	Percentual	Combustível	Velocidade	Acc_Norm	Pedal	RPM	Deflexão
0	1560	2.13	2663.2	44.574	0.90409	76.297	2280.6	7.3435
1	18409	25.18	743.51	25.285	0.64109	11.193	1475.6	10.739
2	51301	70.16	795.1	39.768	0.54096	12.484	1634.4	6.3667
3	1846	2.52	3163.8	63.085	1.0899	74.344	2723.1	8.8732

A coluna Contagem mostra o número de registros atribuídos a cada grupo, e Percentual representa a proporção desses registros em relação ao total. As colunas Combustível, Velocidade, Acc\_Norm, Pedal, RPM e Deflexão apresentam, respectivamente, as médias dos principais indicadores de condução para cada grupo: consumo de combustível, velocidade média, aceleração normalizada, nível de acionamento do pedal, rotação do motor e deflexão do volante. Esses valores médios ajudam a caracterizar o estilo de condução predominante em cada grupo, permitindo distinguir perfis, por exemplo, mais econômicos, mais agressivos ou mais conservadores.

A Tabela 2 detalha a coincidência entre os classificadores, evidenciando a taxa de concordância total, parcial ou nenhuma entre os métodos empregados. Além disso, são exploradas separadamente as coincidências por tipo de classificação (Calmo, Normal e Agressivo), o que permite entender a robustez e a sobreposição entre os critérios adotados.

Tabela 2 – Coincidência entre classificadores

Tipo de coincidência	Contagem	Percentual
Coincidência total (3/3)	17 234	23.57
Coincidência parcial (2/3)	54 322	74.30
Nenhuma coincidência (0/3)	1 560	2.13

A Tabela 3 realiza uma análise cruzada entre os clusters gerados pelo algoritmo K-Means e os grupos definidos com base nas classificações independentes. Essa correspondência oferece uma visão da coerência entre métodos supervisionados e não supervisionados, além de auxiliar na interpretação dos agrupamentos automáticos.

Por fim, a Tabela 4 apresenta as médias das mesmas variáveis da Tabela 1, agora calculadas para cada cluster identificado. Essa apresentação permite uma análise comparativa dos perfis típicos de cada grupo, de acordo com os padrões aprendidos pelo algoritmo de agrupamento.

Tabela 3 – Distribuição de Grupos por Cluster (Análise Cruzada)

Cluster	Grupo	Contagem	Percentual
1	0	18	0.06
	1	11 678	36.00
	2	20 701	63.82
	3	39	0.12
2	0	136	0.38
	1	6 462	17.88
	2	29 326	81.17
	3	207	0.57
3	0	1 406	30.91
	1	269	5.91
	2	1 274	28.01
	3	1 600	35.17

Tabela 4 – Médias das Variáveis por Cluster

Cluster	Contagem	Percentual	Combustível	Velocidade	Acc_Norm	Pedal	RPM	Deflexão
1	32 436	44.36	461.01	16.88	0.701	8.25	1197.7	13.52
2	36 131	49.41	985.90	52.36	0.442	13.33	1915.4	2.48
3	4 549	6.22	3054.9	55.42	0.939	77.72	2538.2	5.28

Além da análise de coincidência geral, foi realizada uma avaliação individual para cada estilo de condução — Agressivo, Normal e Calmo — com base na concordância entre os três classificadores independentes.

Para o estilo Agressivo, observou-se que em apenas 85 casos (0,12%) houve total concordância entre os classificadores. Em 1.761 observações (2,41%), dois classificadores apontaram o estilo como agressivo, enquanto em 17.463 registros (23,88%) apenas um dos sistemas indicou esse padrão. A maioria dos dados (53.807 observações, correspondendo a 73,59%) não foi rotulada como agressiva por nenhum dos classificadores.

No caso do estilo Normal, houve concordância total em 10.583 observações (14,47%). Em 40.718 casos (55,69%), dois classificadores identificaram esse comportamento. Apenas um classificador apontou estilo normal em 20.748 observações (28,38%), enquanto em 1.067 registros (1,46%) nenhum dos métodos classificou a condução como normal.

Para o estilo Calmo, os três classificadores concordaram em 6.566 amostras (8,98%). Já em 48.501 observações (66,33%) houve concordância entre dois classificadores. Em 15.935 casos (21,79%) apenas um método apontou esse padrão, e em 2.114 observações (2,89%) não houve indicação de condução calma por nenhum dos classificadores.

### 3.1.6 Interpretação dos Dados

Como a base de dados utilizada foi originalmente concebida para o desafio de identificação de motoristas, e não especificamente para classificação de estilo de condução, é esperado — e justificado — que a maior parte dos dados seja classificada como pertencente aos estilos "normal" ou "calmo", conforme pode ser observado na Tabela 1. Esse padrão se mantém também na Tabela 3, onde os grupos identificados como normal ou calmo predominam.

Na Tabela 1, observa-se que o Grupo 0, correspondente aos casos de não concordância entre classificadores, representa cerca de 2% dos dados. Em termos de médias das variáveis, esse grupo se assemelha tanto ao Grupo 2 quanto ao Grupo 3, revelando sua natureza ambígua. Essa indefinição afeta especialmente o perfil agressivo: enquanto 23,88% dos dados tiveram ao menos um classificador apontando para esse estilo, apenas 2,53% tiveram pelo menos dois classificadores em concordância com essa classificação. Já para os estilos normal e calmo, as taxas de concordância (duas ou mais classificações coincidentes) são significativamente mais altas: 70,16% e 75,31%, respectivamente.

Ainda na Tabela 1, percebe-se que os casos em que dois classificadores indicam "calmo" somam 66,33%, e em que todos indicam "calmo", 8,98%. No entanto, o Grupo 1 (classificado como calmo) representa apenas cerca de 25% do total. Isso se deve ao fato de que o classificador determinístico só possui dois rótulos: normal e agressivo. Assim, em situações em que os classificadores fuzzy e jerk apontam "calmo" e "normal", ou vice-versa, o sistema de decisão priorizou a classificação como "normal". Isso explica por que o Grupo 2 (normal) acabou sendo significativamente maior do que o Grupo 1.

Esse comportamento também se reflete na Tabela 3, na qual tanto o Cluster 1 quanto o Cluster 2 apresentam maior proporção de amostras do Grupo 2. Entretanto, há uma distinção: o Cluster 1 é mais equilibrado entre os Grupos 1 e 2, indicando que as observações do Grupo 2 nesse cluster apresentam características mais próximas do perfil calmo.

Embora o agrupamento por compatibilidade entre classificadores apresente resultados coerentes, ele possui algumas limitações importantes:

- Os itens classificados como Grupo 0 não apresentam um critério claro de decisão, o que compromete sua interpretabilidade;
- A ausência da classe "calmo" no classificador determinístico dificulta a separação efetiva entre os estilos calmo e normal;
- O modelo trata os classificadores com igual peso, ignorando o fato de que uma classificação isolada pode ser mais representativa do que outras duas mais incertas;
- A lógica de decisão é arbitrária: optar por critérios mais conservadores (uma única classificação como "agressivo" ser suficiente) ou mais restritivos (apenas três concordâncias definem a classe) pode levar a resultados extremos — como aumento de falsos positivos ou excesso de exclusões;
- O modelo é limitado às regras previamente estabelecidas, não sendo capaz de identificar novos padrões ou comportamentos não previstos pelos classificadores.

A utilização de agrupamento não supervisionado por *clusters* atenua essas limitações. Como pode ser observado nas Tabelas 3 e 4, o uso do K-Means permitiu redirecionar observações inicialmente classificadas como Grupo 0, além de refinar a separação entre os estilos. A presença de todos os grupos em todos os clusters evidencia que o modelo foi capaz de ajustar a sensibilidade dos classificadores iniciais e reconhecer novos padrões não contemplados anteriormente. A separação entre os estilos normal e calmo também foi melhor distribuída, enquanto a baixa quantidade de dados agressivos se manteve, o que reforça a justificativa inicial baseada na natureza da base de dados.

A análise das médias das variáveis por cluster mostra coerência com os rótulos atribuídos: o Cluster 3, associado ao estilo agressivo, apresenta os maiores valores médios em todas as variáveis — exceto na deflexão do volante. Este último ponto é esperado, pois maiores deflexões costumam ocorrer em baixas velocidades, típicas de manobras calmas, como estacionamento ou conversões em baixa velocidade.

Destaca-se ainda a diferença no consumo de combustível: o estilo agressivo apresenta uma média de consumo aproximadamente três vezes maior que o estilo normal, e cerca de 6,6 vezes maior que o estilo calmo. Esse dado evidencia o impacto direto do estilo de condução sobre a eficiência energética, reforçando a relevância da análise e indicando um caminho promissor para futuras investigações e iniciativas de incentivo à condução econômica e segura.

### 3.1.7 Considerações Parciais

Esta seção buscou explorar diferentes estratégias para a classificação de estilos de condução a partir de dados de telemetria veicular. Foram consideradas abordagens consolidadas na literatura, como modelos fuzzy aplicados às dinâmicas lateral e longitudinal, análise estatística baseada no jerk (variação da aceleração) e regras determinísticas fundamentadas em limites operacionais de parâmetros do veículo, tais como rotação do motor, posição do pedal do acelerador e deflexão do volante. A partir desse panorama, desenvolveu-se uma metodologia de agrupamento utilizando o algoritmo K-Means, com o objetivo de investigar sua capacidade de identificar perfis de condução de forma não supervisionada e avaliar como seus resultados se relacionam com as classificações obtidas pelas demais abordagens.

Como principal contribuição, este trabalho demonstra a compatibilidade parcial entre os métodos clássicos presentes na literatura e destaca como esses podem ser utilizados como ferramenta auxiliar para a interpretação dos agrupamentos gerados. A análise cruzada permitiu validar os agrupamentos obtidos, além de oferecer uma visão mais robusta dos diferentes perfis de condução. Essa abordagem contribui para o avanço na compreensão do comportamento dos condutores, reforçando o potencial de técnicas não supervisionadas na detecção de padrões de condução, com impactos diretos em aplicações de segurança, eficiência energética e manutenção preditiva no setor automotivo.

Na sequência, a rotulagem proposta será utilizada para treinar um modelo de aprendizado de máquina supervisionado para a classificação de estilos de condução. Esse modelo

será, então, aplicado em tempo real para fornecer feedback aos condutores, promovendo uma condução mais segura, eficiente e sustentável.

### 3.2 Desenvolvimento do Algoritmo Neuro-Fuzzy

Descrever a proposta de uso de um algoritmo neuro-fuzzy para classificar os estilos de direção. Justificar a escolha da abordagem híbrida (capacidade de generalização das redes neurais + interpretabilidade dos sistemas fuzzy). Explicar brevemente a arquitetura pretendida, os dados de entrada e a lógica de inferência. Deixar claro que o modelo será treinado com os dados previamente rotulados.

### 3.3 Desenvolvimento do Hardware para Coleta de Dados

Apresentar a proposta de construção de um dispositivo baseado em microcontrolador (ex: ESP32, Arduino + módulo CAN, FPGA) capaz de realizar a coleta dos dados diretamente da porta OBD2 dos veículos. Explicar como o dispositivo será utilizado para: - Validar os dados dos datasets com dados reais; - Realizar coletas com motoristas voluntários; - Testar se as abordagens de rotulagem e classificação são consistentes com a realidade. Mencionar o ambiente de testes (ex: campus, laboratório FutureLab) e protocolos de segurança.

### 3.4 Desenvolvimento do Algoritmo de Aprendizado Federado

### 3.5 Desenvolvimento de Sistema de Feedback



## **4 ANÁLISE E DISCUSSÃO DOS RESULTADOS**

Cada capítulo deve conter uma pequena introdução (tipicamente, um ou dois parágrafos) que deve deixar claro o objetivo e o que será discutido no capítulo, bem como a organização do capítulo.

## 5 SOBRE AS ILUSTRAÇÕES

A seguir exemplifica-se como inserir ilustrações no corpo do trabalho. As ilustrações serão indexadas automaticamente em suas respectivas listas. A numeração sequencial de figuras, tabelas e equações também ocorre de modo automático.


Referências cruzadas são obtidas através dos comandos `\label{}` e `\ref{}`. Sendo assim, não é necessário por exemplo, saber que o número de certo capítulo é 2 para colocar o seu número no texto. Outra forma que pode ser utilizada é esta: [Capítulo 2](#), facilitando a inserção, remoção e manejo de elementos numerados no texto sem a necessidade de renumerar todos esses elementos.

## 6 FIGURAS

Exemplo de como inserir uma figura. A [Figura 5](#) aparece automaticamente na lista de figuras. Para saber mais sobre o uso de imagens no  $\text{\LaTeX}$  consulte literatura especializada ([GOOSSENS et al., 2007](#)).

Os arquivos das figuras devem ser armazenados no diretório de `"/dados"`.

Figura 5 – Exemplo de Figura



Fonte: [IRL \(2014\)](#)

## 7 QUADROS E TABELAS

Exemplo de como inserir o [Quadro 1](#) e a [Tabela 5](#). Ambos aparecem automaticamente nas suas respectivas listas. Para saber mais informações sobre a construção de tabelas no  $\text{\LaTeX}$  consulte literatura especializada ([MITTELBAACH et al., 2004](#)).

Ambos os elementos (Quadros e Tabelas) devem ser criados em arquivos separados para facilitar manutenção e armazenados no diretório de `"/dados"`.

Quadro 1 – Exemplo de Quadro.

<b>BD Relacionais</b>	<b>BD Orientados a Objetos</b>
Os dados são passivos, ou seja, certas operações limitadas podem ser automaticamente acionadas quando os dados são usados. Os dados são ativos, ou seja, as solicitações fazem com que os objetos executem seus métodos.	Os processos que usam dados mudam constantemente.

Fonte: [Barbosa et al. \(2004\)](#)

A diferença entre quadro e tabela está no fato que um quadro é formado por linhas horizontais e verticais. Deve ser utilizado quando o conteúdo é majoritariamente não-numérico. O número do quadro e o título vem acima do quadro, e a fonte, deve vir abaixo. E Uma tabela é formada apenas por linhas verticais. Deve ser utilizada quando o conteúdo é majoritariamente numérico. O número da tabela e o título vem acima da tabela, e a fonte, deve vir abaixo, tal como no quadro.

Tabela 5 – Resultado dos testes.

	Valores 1	Valores 2	Valores 3	Valores 4
Caso 1	0,86	0,77	0,81	163
Caso 2	0,19	0,74	0,25	180
Caso 3	1,00	1,00	1,00	170

Fonte: [Barbosa et al. \(2004\)](#)

## 8 EQUAÇÕES

Exemplo de como inserir a [Equação \(5\)](#) e a [Eq. 6](#) no corpo do texto <sup>1</sup>. Observe que foram utilizadas duas formas distintas para referenciar as equações.

$$X(s) = \int_{t=-\infty}^{\infty} x(t) e^{-st} dt \quad (5)$$

$$F(u, v) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f(m, n) \exp \left[ -j2\pi \left( \frac{um}{M} + \frac{vn}{N} \right) \right] \quad (6)$$

---

<sup>1</sup>Deve-se atentar ao fato de a formatação das equações ficar muito boa esteticamente.

## 9 ALGORITMOS

Exemplo de como inserir um algoritmo. Para inserção de algoritmos utiliza-se o pacote `algorithm2e` que já está devidamente configurado dentro do template.

Os algoritmos devem ser criados em arquivos separados para facilitar manutenção e armazenados no diretório de `"/dados"`.

---

**Algoritmo 1:** Exemplo de Algoritmo

---

**Input:** o número  $n$  de vértices a remover, grafo original  $G(V, E)$

**Output:** grafo reduzido  $G'(V, E)$

$removidos \leftarrow 0$

**while**  $removidos < n$  **do**

$v \leftarrow \text{Random}(1, \dots, k) \in V$

**for**  $u \in adjacentes(v)$  **do**

        remove aresta  $(u, v)$

$removidos \leftarrow removidos + 1$

**end**

**if** *há componentes desconectados* **then**

        remove os componentes desconectados

**end**

**end**

---

## 10 SOBRE AS LISTAS

Para construir listas de "*bullets*" ou listas enumeradas, inclusive listas aninhadas, é utilizado o pacote `paralist`.

Exemplo de duas listas não numeradas aninhadas, utilizando o comando `\itemize`. Observe a indentação, bem como a mudança automática do tipo de "*bullet*" nas listas aninhadas.

- item não numerado 1
- item não numerado 2
  - subitem não numerado 1
  - subitem não numerado 2
  - subitem não numerado 3
- item não numerado 3

Exemplo de duas listas numeradas aninhadas, utilizando o comando `\enumerate`. Observe a numeração progressiva e indentação das listas aninhadas.

1. item numerado 1
2. item numerado 2
  - a) subitem numerado 1
  - b) subitem numerado 2
  - c) subitem numerado 3
3. item numerado 3

## **11 SOBRE AS CITAÇÕES E CHAMADAS DE REFERÊNCIAS**

Citações são trechos de texto ou informações obtidas de materiais consultados quando da elaboração do trabalho. São utilizadas no texto com o propósito de esclarecer, completar e embasar as ideias do autor. Todas as publicações consultadas e utilizadas (por meio de citações) devem ser listadas, obrigatoriamente, nas referências bibliográficas, para preservar os direitos autorais. São classificadas em citações indiretas e diretas.



## 12 CITAÇÕES INDIRETAS

É a transcrição, com suas próprias palavras, das idéias de um autor, mantendo-se o sentido original. A citação indireta é a maneira que o pesquisador tem de ler, compreender e gerar conhecimento a partir do conhecimento de outros autores. Quanto à chamada da referência, ela pode ser feita de duas maneiras distintas, conforme o nome do(s) autor(es) façam parte do seu texto ou não. Exemplo de chamada fazendo parte do texto:

Enquanto [Maturana e Varela \(2003\)](#) defendem uma epistemologia baseada na biologia. Para os autores, é necessário rever ....

A chamada de referência foi feita com o comando `\citeonline{chave}`, que produzirá a formatação correta.

A segunda forma de fazer uma chamada de referência deve ser utilizada quando se quer evitar uma interrupção na sequência do texto, o que poderia, eventualmente, prejudicar a leitura. Assim, a citação é feita e imediatamente após a obra referenciada deve ser colocada entre parênteses. Porém, neste caso específico, o nome do autor deve vir em caixa alta, seguido do ano da publicação. Exemplo de chamada não fazendo parte do texto:

Há defensores da epistemologia baseada na biologia que argumentam em favor da necessidade de ... ([MATURANA; VARELA, 2003](#)).

Nesse caso a chamada de referência deve ser feita com o comando `\cite{chave}`, que produzirá a formatação correta.

## 13 CITAÇÕES DIRETAS

É a transcrição ou cópia de um parágrafo, de uma frase, de parte dela ou de uma expressão, usando exatamente as mesmas palavras adotadas pelo autor do trabalho consultado.

Quanto à chamada da referência, ela pode ser feita de qualquer das duas maneiras já mencionadas nas citações indiretas, conforme o nome do(s) autor(es) façam parte do texto ou não. Há duas maneiras distintas de se fazer uma citação direta, conforme o trecho citado seja longo ou curto.

Quando o trecho citado é longo (4 ou mais linhas) deve-se usar um parágrafo específico para a citação, na forma de um texto recuado (4 cm da margem esquerda), com tamanho de letra menor e espaçamento entrelinhas simples. Exemplo de citação longa:

Desse modo, opera-se uma ruptura decisiva entre a reflexividade filosófica, isto é a possibilidade do sujeito de pensar e de refletir, e a objetividade científica. Encontramo-nos num ponto em que o conhecimento científico está sem consciência. Sem consciência moral, sem consciência reflexiva e também subjetiva. Cada vez mais o desenvolvimento extraordinário do conhecimento científico vai tornar menos praticável a própria possibilidade de reflexão do sujeito sobre a sua pesquisa (SILVA; SOUZA, 2000, p. 28).

Para fazer a citação longa deve-se utilizar os seguintes comandos:

```
\begin{citacao}  
<texto da citacao>  
\end{citacao}
```

No exemplo acima, para a chamada da referência o comando `\cite[p. ~28]{Silva2000}` foi utilizado, visto que os nomes dos autores não são parte do trecho citado. É necessário também indicar o número da página da obra citada que contém o trecho citado.

Quando o trecho citado é curto (3 ou menos linhas) ele deve inserido diretamente no texto entre aspas. Exemplos de citação curta:

A epistemologia baseada na biologia parte do princípio de que "assumo que não posso fazer referência a entidades independentes de mim para construir meu explicar"(MATURANA; VARELA, 2003, p. 35).

A epistemologia baseada na biologia de Maturana e Varela (2003, p. 35) parte do princípio de que "assumo que não posso fazer referência a entidades independentes de mim para construir meu explicar".

## 14 DETALHES SOBRE AS CHAMADAS DE REFERÊNCIAS

Outros exemplos de comandos para as chamadas de referências e o resultado produzido por estes:

```
Maturana e Varela (2003) \citeonline{Maturana2003}
Barbosa et al. (2004) \citeonline{Barbosa2004}
(SILVA; SOUZA, 2000, p. 28) \cite[p.~28]{Silva2000}
Silva e Souza (2000, p. 33) \citeonline[p.~33]{v}
(MATURANA; VARELA, 2003, p. 35) \cite[p.~35]{Maturana2003}
Maturana e Varela (2003, p. 35) \citeonline[p.~35]{Maturana2003}
(BARBOSA et al., 2004; MATURANA; VARELA, 2003) \cite{Barbosa2004,Maturana2003}
```

## 15 SOBRE AS REFERÊNCIAS BIBLIOGRÁFICAS

A bibliografia é feita no padrão Bib $\text{\TeX}$ . As referências são colocadas em um arquivo separado. Neste template as referências são armazenadas no arquivo "base-referencias.bib".

Existem diversas categorias documentos e materiais componentes da bibliografia. A classe abn $\text{\TeX}$  define as seguintes categorias (entradas):

```
@book
@inbook
@article
@phdthesis
@mastersthesis
@monography
@techreport
@manual
@proceedings
@inproceedings
@journalpart
@booklet
@patent
@unpublished
@misc
```

Cada categoria (entrada) é formatada pelo pacote [abn \$\text{\TeX}\$ 2](#) e [Araujo \(2014b\)](#) de uma forma específica. Algumas entradas foram introduzidas especificamente para atender à norma [ABNT \(2002\)](#), são elas: @monography, @journalpart,@patent. As demais entradas são padrão Bib $\text{\TeX}$ . Para maiores detalhes, refira-se a [abn \$\text{\TeX}\$ 2 e Araujo \(2014b\)](#), [abn \$\text{\TeX}\$ 2 e Araujo \(2014a\)](#), [Araujo e abn \$\text{\TeX}\$ 2 \(2014\)](#).

## 16 NOTAS DE RODAPÉ

As notas de rodapé pode ser classificadas em duas categorias: notas explicativas<sup>1</sup> e notas de referências. A notas de referências, como o próprio nome já indica, são utilizadas para colocar referências e/ou chamadas de referências sob certas condições.

---

<sup>1</sup>é o tipo mais comum de notas que destacam, explicam e/ou complementam o que foi dito no corpo do texto, como esta nota de rodapé, por exemplo.

## 17 CONCLUSÃO

Parte final do texto, na qual se apresentam as conclusões do trabalho acadêmico. É importante fazer uma análise crítica do trabalho, destacando os principais resultados e as contribuições do trabalho para a área de pesquisa.

### 17.1 TRABALHOS FUTUROS

Também deve indicar, se possível e/ou conveniente, como o trabalho pode ser estendido ou aprimorado.

### 17.2 CONSIDERAÇÕES FINAIS

Encerramento do trabalho acadêmico.

## Referências

ABNTEX2; ARAUJO, L. C. **A classe abntex2**: Documentos técnicos e científicos brasileiros compatíveis com as normas abnt. [S.l.], 2014. 46 p. Disponível em: <<http://abntex2.googlecode.com/>>. Acesso em: 12 de setembro de 2014. Citado na página 37.

ABNTEX2; ARAUJO, L. C. **O pacote abntex2cite**: Estilos bibliográficos compatíveis com a abnt nbr 6023. [S.l.], 2014. 91 p. Disponível em: <<http://abntex2.googlecode.com/>>. Acesso em: 12 de setembro de 2014. Citado na página 37.

ALAM, M. S.; MCNABOLA, A. A critical review and assessment of eco-driving policy technology: Benefits limitations. **Transport Policy**, v. 35, p. 42–49, 2014. ISSN 0967-070X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0967070X14001152>>. Citado na página 4.

ALJAAFREH, A.; ALSHABATAT, N.; AL-DIN, M. N. Driving style recognition using fuzzy logic. In: **2012 IEEE International Conference on Vehicular Electronics and Safety, ICVES 2012**. [S.l.: s.n.], 2012. p. 460–463. ISBN 978-1-4673-0992-9. Citado 5 vezes nas páginas 7, 8, 9, 14 e 16.

ALMEIDA, L. G. de. **Driver's Behavior Classification in Vehicular Communication Networks for Commercial Vehicles**. Junho 2023. 91 f. Dissertação (MASTER DEGREE PROGRAM IN COMPUTER SCIENCE AND TECHNOLOGY) — UNIVERSIDADE FEDERAL DE ITAJUBÁ - UNIFEI, Itajubá, 2023. Citado 2 vezes nas páginas 6 e 15.

ARAUJO, L. C.; ABNTEX2. **O pacote abntex2cite**: Tópicos específicos da abnt nbr 10520:2002 e o estilo bibliográfico alfabético (sistema autor-data). [S.l.], 2014. 23 p. Disponível em: <<http://abntex2.googlecode.com/>>. Acesso em: 12 de setembro de 2014. Citado na página 37.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 6023**: Informação e documentação — referências — elaboração. Rio de Janeiro, 2002. 24 p. Citado na página 37.

BÄR, T. et al. Probabilistic driving style determination by means of a situation based analysis of the vehicle data. In: IEEE. **2011 14th International IEEE Conference on Intelligent Transportation Systems (ITSC)**. [S.l.], 2011. p. 1698–1703. Citado na página 7.

BARBOSA, C. et al. **Testando a utilização de “et al.”**. 2. ed. Cidade: Editora, 2004. Citado 2 vezes nas páginas 29 e 36.

BOUHSISSIN, S.; SAEL, N.; BENABBOU, F. Driver behavior classification: A systematic literature review. **IEEE Access**, PP, 02 2023. Citado 4 vezes nas páginas 5, 8, 9 e 12.

CAVALCANTE, L. H. **Sistema de Monitoramento Automotivo via Rede CAN**. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Mecatrônica) — Instituto Federal de Educação, Ciência e Tecnologia de Santa Catarina, Câmpus Florianópolis, Florianópolis, jul. 2018. Orientador: Adriano Regis. Citado na página 6.

CHELLAPANDI, V. P. et al. A survey of federated learning for connected and automated vehicles. In: IEEE. **2023 IEEE 26th International Conference on Intelligent Transportation Systems (ITSC)**. [S.l.], 2023. p. 2485–2492. Citado 2 vezes nas páginas 2 e 10.

CHEN, L.; TORSTENSSON, M.; ENGLUND, C. Federated learning to enable automotive collaborative ecosystem: opportunities and challenges. In: **Virtual ITS European Congress, 9-10 November 2020**. [S.l.: s.n.], 2020. Citado 2 vezes nas páginas 2 e 10.

CNN Brasil. **Lula assina decreto que regulamenta o MOVER**. 2024. <<https://www.cnnbrasil.com.br/economia/macroeconomia/lula-assina-decreto-que-regulamenta-o-mover/>>. Publicado em: 5 dez. 2024. Acesso em: 6 maio 2025. Citado na página 2.

DAI, J. et al. Mobile phone based drunk driving detection. In: IEEE. **2010 4th international conference on pervasive computing technologies for healthcare**. [S.l.], 2010. p. 1–8. Citado na página 8.

DÖRR, D.; GRABENGISSER, D.; GAUTERIN, F. Online driving style recognition using fuzzy logic. In: IEEE. **17th international IEEE conference on intelligent transportation systems (ITSC)**. [S.l.], 2014. p. 1021–1026. Citado na página 7.

DU, J. **Research on Eco-Mode of Hybrid Powertrain Based on Working Cycles and Drivers' Operating Types**. Tese (Doutorado) — Tsinghua University Beijing, China, 2017. Citado na página 4.

FAZEEN, M. et al. Safe driving using mobile phones. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, v. 13, n. 3, p. 1462–1468, 2012. Citado na página 8.

FUGIGLANDO, U. et al. Driving behavior analysis through can bus data in an uncontrolled environment. **IEEE Transactions on Intelligent Transportation Systems**, PP, 10 2017. Citado 3 vezes nas páginas 6, 8 e 16.

FUNDEP/UFMG. **MOVER — Mobilidade Verde e Inovação**. 2025. <<https://mover.fundep.ufmg.br/mover/>>. Acesso em: 6 maio 2025. Citado 2 vezes nas páginas 1 e 2.

GHATEE, M.; EFTEKHARI, H. Hybrid of discrete wavelet transform and adaptive neuro fuzzy inference system for overall driving behavior recognition. **Transportation Research Part F Traffic Psychology and Behaviour**, v. 58, p. 782–796, 07 2018. Citado na página 5.

GOOSSENS, M. et al. **The LaTeX graphics companion**. 2. ed. Boston: Addison-Wesley, 2007. Citado na página 28.

GÜNTHER, M.; KACPERSKI, C.; KREMS, J. F. Can electric vehicle drivers be persuaded to eco-drive? a field study of feedback, gamification and financial rewards in germany. **Energy Research & Social Science**, Elsevier, v. 63, p. 101407, 2020. Citado na página 4.

HIGGS, B.; ABBAS, M. A two-step segmentation algorithm for behavioral clustering of naturalistic driving styles. In: IEEE. **16th international ieee conference on intelligent transportation systems (itsc 2013)**. [S.l.], 2013. p. 857–862. Citado na página 7.

IRL. **Internet Research Laboratory**. 2014. Disponível em: <<http://irl.cs.ucla.edu/topology>>. Acesso em: 8 de março de 2014. Citado na página 28.

JAMES, L. **Road rage and aggressive driving: Steering clear of highway warfare**. [S.l.]: Prometheus Books, 2009. Citado na página 8.

JOHNSON, D. A.; TRIVEDI, M. M. Driving style recognition using a smartphone as a sensor platform. In: IEEE. **2011 14th International IEEE conference on intelligent transportation systems (ITSC)**. [S.l.], 2011. p. 1609–1615. Citado na página 7.



- KARROUCHI, M. et al. Driving behavior assessment: A practical study and technique for detecting a driver's condition and driving style. **Transportation Engineering**, Volume 14, p. 100217, 11 2023. Citado 2 vezes nas páginas 15 e 17.
- KIM, K.; PARK, J.; LEE, J. Fuel economy improvement of urban buses with development of an eco-drive scoring algorithm using machine learning. **Energies**, v. 14, p. 4471, 07 2021. Citado 2 vezes nas páginas 8 e 10.
- KNAPPE, G. et al. Driving simulator as an evaluation tool—assessment of the influence of field of view and secondary tasks on lane keeping and steering performance. In: **20th International Technical Conference on the Enhanced Safety of Vehicles (ESV) National Highway Traffic Safety Administration**. [S.l.: s.n.], 2007. Citado na página 8.
- KWAK, B. I.; WOO, J.; KIM, H. K. Know your master: Driver profiling-based anti-theft method. In: **PST 2016**. [S.l.: s.n.], 2016. Citado na página 13.
- LLOYD, S. Least squares quantization in pcm. **IEEE transactions on information theory**, IEEE, v. 28, n. 2, p. 129–137, 1982. Citado na página 12.
- MANZONI, V. et al. Driving style estimation via inertial measurements. In: **13th International IEEE Conference on Intelligent Transportation Systems**. [S.l.: s.n.], 2010. p. 777–782. Citado na página 4.
- MATURANA, H. R.; VARELA, F. J. **A Árvore do Conhecimento**: as bases biológicas da compreensão humana. 3. ed. São Paulo: Editora Palas Athena, 2003. Citado 3 vezes nas páginas 34, 35 e 36.
- MIERLO, J. V. et al. Driving style and traffic measures - influence on vehicle emissions and fuel consumption. **Proceedings of the Institution of Mechanical Engineers Part D Journal of Automobile Engineering**, v. 218, p. 43–50, 01 2004. Citado na página 4.
- MIKULIĆ, I.; BOŠKOVIĆ, I.; ZOVAK, G. Effects of driving style and vehicle maintenance on vehicle roadworthiness. **Promet - TrafficTransportation**, v. 32, p. 667–677, 10 2020. Citado na página 10.
- MITTELBAACH, F. et al. **The LaTeX companion**. 2. ed. Boston: Addison-Wesley, 2004. Citado na página 29.
- MURPHEY, Y.; MILTON, R.; KILIARIS, L. Driver's style classification using jerk analysis. In: **2009 IEEE Workshop on Computational Intelligence in Vehicles and Vehicular Systems**. [S.l.: s.n.], 2009. p. 23 – 28. Citado 4 vezes nas páginas 8, 9, 15 e 19.
- PAN, X. et al. Implications of near-term mitigation on china's long-term energy transitions for aligning with the paris goals. **Energy economics**, Elsevier, v. 90, p. 104865, 2020. Citado na página 1.
- PARK, K. H.; KIM, H. K. This car is mine!: Automobile theft countermeasure leveraging driver identification with generative adversarial networks. **arXiv preprint arXiv:1911.09870**, 2019. Citado na página 6.
- RAMOS, H. S. et al. Aprendizado federado aplicado à internet das coisas. In: **XXXIX Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2021)**. Brasil: SBC, 2021. cap. 5. Citado 2 vezes nas páginas 2 e 9.

Robert Bosch GmbH. **CAN Specification**. Version 2.0. Postfach 50, D-7000 Stuttgart 1, 1991. Also known as the CAN 2.0 specification. Citado na página 6.

SILVA, J.; SOUZA, J. a. L. **A Inteligência da Complexidade**. São Paulo: Editora Petrópolis, 2000. Citado 2 vezes nas páginas 35 e 36.

SIMSEK, Y. et al. An analysis of additional energy requirement to meet the sustainable development goals. **Journal of Cleaner Production**, Elsevier, v. 272, p. 122646, 2020. Citado na página 1.

SINGH, H.; KATHURIA, A. Profiling drivers to assess safe and eco-driving behavior – a systematic review of naturalistic driving studies. **Accident Analysis Prevention**, v. 161, p. 106349, 2021. ISSN 0001-4575. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0001457521003808>>. Citado 5 vezes nas páginas 2, 5, 7, 8 e 9.

STEPHENS, R. A review of gamified approaches to encouraging eco-driving. **Frontiers in Psychology**, v. 13, p. 970851, 09 2022. Citado na página 10.

USC Viterbi School of Engineering. **Grand Challenges Scholars Program**. 2025. <<https://viterbiundergrad.usc.edu/gcsp/>>. Acesso em: 6 maio 2025. Citado na página 1.

VAIANA, R. et al. Driving behavior and traffic safety: an acceleration-based safety evaluation procedure for smartphones. **Modern Applied Science**, Canadian Center of Science and Education, v. 8, n. 1, p. 88, 2014. Citado na página 8.

VERNIZZI, R. C. **Desenvolvimento de dispositivo para aquisição de dados da rede CAN de um veículo e transmissão através da Internet**. Monografia (Trabalho de Conclusão de Curso) — Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos, 2024. Citado na página 6.

VUJIĆ, M.; ŠEMANJSKI, I.; VIDAN, P. Improving energy efficiency by advanced traffic control systems. **Transactions on maritime science**, Sveučilište u Splitu, Pomorski fakultet, v. 4, n. 02, p. 119–126, 2015. Citado na página 1.

XU, J. et al. An eco-score system incorporating driving behavior, vehicle characteristics, and traffic conditions. **Transportation Research Part D: Transport and Environment**, v. 95, p. 102866, 2021. ISSN 1361-9209. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S136192092100167X>>. Citado na página 5.

XU, L. et al. Establishing style-oriented driver models by imitating human driving behaviors. **IEEE Transactions on Intelligent Transportation Systems**, IEEE, v. 16, n. 5, p. 2522–2530, 2015. Citado na página 7.

XU, N. et al. An overview of eco-driving theory, capability evaluation, and training applications. **Sensors**, v. 21, n. 19, 2021. ISSN 1424-8220. Disponível em: <<https://www.mdpi.com/1424-8220/21/19/6547>>. Citado 2 vezes nas páginas 4 e 5.

## Apêndices

## **APÊNDICE A – Nome do apêndice**

Lembre-se que a diferença entre apêndice e anexo diz respeito à autoria do texto e/ou material ali colocado.

Caso o material ou texto suplementar ou complementar seja de sua autoria, então ele deverá ser colocado como um apêndice. Porém, caso a autoria seja de terceiros, então o material ou texto deverá ser colocado como anexo.

Caso seja conveniente, podem ser criados outros apêndices para o seu trabalho acadêmico. Basta recortar e colar este trecho neste mesmo documento. Lembre-se de alterar o "label" do apêndice.

Não é aconselhável colocar tudo que é complementar em um único apêndice. Organize os apêndices de modo que, em cada um deles, haja um único tipo de conteúdo. Isso facilita a leitura e compreensão para o leitor do trabalho.

**APÊNDICE B – Nome do outro apêndice**

conteúdo do novo apêndice

Anexos

## **ANEXO A – Nome do anexo**

Lembre-se que a diferença entre apêndice e anexo diz respeito à autoria do texto e/ou material ali colocado.

Caso o material ou texto suplementar ou complementar seja de sua autoria, então ele deverá ser colocado como um apêndice. Porém, caso a autoria seja de terceiros, então o material ou texto deverá ser colocado como anexo.

Caso seja conveniente, podem ser criados outros anexos para o seu trabalho acadêmico. Basta recortar e colar este trecho neste mesmo documento. Lembre-se de alterar o "label" do anexo.

Organize seus anexos de modo a que, em cada um deles, haja um único tipo de conteúdo. Isso facilita a leitura e compreensão para o leitor do trabalho. É para ele que você escreve.

**ANEXO B – Nome do outro anexo**

conteúdo do outro anexo